1 VII 2017

Korpusy językowe i wyszukiwarki korpusowe a badania nad współczesnymi tendencjami języków słowiańskich

Joanna Satoła-Staśkowiak
Instytut Slawistyki PAN, Polska
joannasat@op.pl, joanna.satola@ispan.waw.pl

Language corpora and corpora search engines research on modern trends of Slavic languages.
The objective of the article was a comparative description of modern trends of Slavic languages (Polish and Bulgarian) based on selected language corpora available on the Internet and their search engines as well as on the co-created by the author of the article The Polish-Bulgarian-Russian Parallel Corpus. The described methods of language corpora operation, the possibilities of self-creation and development encourage linguists to use them on a larger scale - not as a curiosity but as a reliable tool to support contemporary language studies.
Keywords: trends of modern Slavic languages, neosemantisms, neologisms, language corpora, The Polish-Bulgarian-Russian Parallel Corpus

1.0. W artykule za cel obrano konfrontatywny opis współczesnych tendencji języków słowiańskich (języka polskiego i bułgarskiego) w oparciu o wybrane dostępne w sieci korpusy językowe i ich wyszukiwarki – także o współtworzony przez autorkę artykułu *Równoległy korpus polsko-bułgarsko-rosyjski*. Opisywane coraz częściej metody działania korpusów, możliwości ich samotworzenia i rozwijania zachęcają językoznawców do korzystania z nich na szerszą skalę – nie jako z ciekawostki, a z rzetelnego narzędzia wspierającego współczesne badania językowe.

1.1. Zwiększająca się sukcesywnie ilość projektów naukowych, referatów i opisujących narzędzia artykułów zachęca do prób i śledzenia nowinek, których celem jest pomoc w pracy badawczej. Wspomniane narzędzia nie są jednak przeznaczone wyłącznie dla specjalistów (tłumaczy, językoznawców). Wiele z nich powstaje z myślą o studentach, redaktorach tekstów, używających np. referencyjnych korpusów językowych do weryfikacji stylu wypowiedzi, a także konfrontacji opisu języka (jego płaszczyzny *parole*) w odniesieniu do spontanicznej, dynamicznej komunikacji codziennej.

2.0. Dzięki wyszukiwarkom i korpusom językowym (języka pisanego i mówionego)[1] wiemy, że współczesne języki słowiańskie z łatwością dopuszczają: **potocyzmy**,[2] które umiejętnie wplatają się do języka ogólnego. Przykłady takiego zjawiska obserwowane są nader często w polskiej komunikacji oficjalnej, np. programach publicystycznych, programach porannych, publicznych wypowiedziach polityków, czyli tam, gdzie jeszcze parenaście lat temu nie było to możliwe. Mnożą się słowa typu: *wykon* (zamiast wykonanie), *info* (zamiast informacja), *gadanie* (zamiast mówienie).

[1] Por. http://korpusy.net/inne-jezyki/czeski-korpus-narodowy.html; http://korpusy.net/korpusy-jezyka-polskiego/korpus-pelcra.html; http://korpusy.net/korpusy-jezyka-polskiego/korpus-pwn.html; http://korpus.ia.uni.lodz.pl/; ;https://clarin-pl.eu/dspace/handle/11321/308 https://clarin-pl.eu/dspace/handle/11321/308; http://search.dcl.bas.bg/; http://dcl.bas.bg/bulnc/;

[2] Język potoczny „wchodzi w nowe rejestry". Powodem jest świadome „dążenie do rozhermetyzowania polszczyzny oficjalnej powojennego pięćdziesięciolecia (po roku 1989 określanej mianem *peerelowskiej*), albo w imię lansowanej przez nie postawy luzu przejętej z Europy Zachodniej i Ameryki" (Waszakowa 2011: 3).

2.1. Wśród tendencji współczesnych języków słowiańskich zauważa się **wulgaryzację**, będącą dowodem na **brutalizację** języka. Za przykład może posłużyć słowo *zajebiście* (świetnie) i jego wariant: *zajefajnie.* Dodatkowo, co zaskakujące, ten robiący karierę w języku młodych Polaków wulgaryzm używany jest w kontekście pozytywnym, dla odzwierciedlenia zachwytu i akceptacji, podczas gdy większość ma charakter pejoratywny, co daje się zaobserwować w przypadku takich neologizmów, jak rzeczownik: *uchył* (osoba niepełnosprawna umysłowo), oraz wulgaryzmy będące efektem cięć morfologicznych, takie jak: *wkurw* (od wkurwić: silne zdenerwowanie, wściekłość).

Język bułgarski posiada dużą reprezentację słów wulgarnych. W tej kwestii jest równie „twórczy" jak język polski i pozostałe języki słowiańskie, z tą różnicą, że żaden z wulgaryzmów nie stał się w języku bułgarskim tak popularny jak opisywane wyżej i bardzo często używane polskie słowa *zajebisty* czy *zajefajny.*

Należy rozgraniczyć umyślne i nieumyślne użycie niektórych słów. Odróżnienie tego rodzaju wypowiedzi nie jest problematyczne, ponieważ wypowiedziom nieumyślnym towarzyszą najczęściej skrępowanie nadawcy komunikatu i przeprosiny po „wulgarnej" wypowiedzi.

> *Gdyby ci liberałowie PiS-owcy przystąpili do Platformy, to byśmy mieli, kurwa… Ups! Przepraszam.*[3]

Słowa o wysokim stopniu wulgarności wypowiadane celowo „robią karierę" w obu językach i wśród wszystkich grup społecznych, niestety także wśród ludzi wykształconych.

Brutalizacja, a szczególnie **wulgaryzacja** świadczą o lekceważącej postawie wobec ogólnie ustalonych zasad zachowania werbalnego i postępowania w ogóle.

2.2. We współczesnych językach polskim i bułgarskim obserwowana jest **silna dominacja wyrazów obcych**,[4] pochodzących głównie z języka angielskiego (sporadycznie tylko z niemieckiego, francuskiego, rosyjskiego, łaciny i innych), która wyraża się: <u>w dokładnych zapożyczeniach z oryginalną pisownią</u>, np. **w języku polskim**: *power* (1. moc, siła; 2. energia), *LOL* (kupa śmiechu), *wow* (jako wyraz aprobaty: no no!, o! ale jaja!), *deck* (powalający, świetny itp.; jako kolejny wariant przysłówków: *trendy*, *cool*); **w języku bułgarskim** z pomocą transliteracji: *лифтинг* (ang. *lifting*), *тренд* (ang. *trend*), *допинг* (ang. *doping*), *аватар* (ang. *avatar*); <u>w zapożyczeniach akustycznych z polską pisownią</u>: *czilałt* (od ang. *chill-out* – 'pełen relaks'), *hejter* (od ang. *hater* – 'człowiek nienawidzący'), *hendmejd*[5] (od ang. *handmade* 'ręcznie wykonany, rękodzieło'), *fejm* (od ang. *fame* – 'sława'); oraz <u>w akustycznych zapożyczeniach z bułgarską pisownią</u> [РНДБЕ 2010]: *криейтив* (od ang. *creative* 'twórczy, kreatywny, pomysłowy'), *мостер* (od ang. *toaster*), *чилаут* (od ang. *chill-out* – 'pełen relaks'), *флаш* (od ang. *flash memory*

---

[3] Takie zdanie wypowiedział w programie na żywo prowadzący „Drugie śniadanie mistrzów" Marcin Meller.

[4] Wspomniana już dominacja wyrazów obcych w językach polskim i bułgarskim może wyrażać się też <u>w odniesieniu (często żartobliwym) do języka angielskiego</u>. **W języku polskim** jako przykłady można przywołać czasowniki: *kolnąć* (od ang. call), *tokować* (od ang. *talk*), *lukać* (od ang. *look*), *lajkować* (od ang. *like*).

[5] „Wysokie obcasy", nr 3, lipiec 2013, s. 58.

– ‘pamięć flash’), *куул* (od ang. cool – ‘świetny, wyluzowany, powalający’).

– *Ktoś się sfrajerzył i nagrał **dissa**..?* (www.miejski.pl)
– *Czy jeszcze tylko piątek i relaks trans?*
– *E tam, ja mam **czilałt** cały tydzień*. (Cytaty z artykułu M. Karaś i I. Witkowskiej pt. *Taka, kurwa, konwencja*, „Przekrój” nr 27/2012)
– *Mój mąż zaklął szpetnie, jak się dowiedział, że niepotrzebnie wydał **kesz**.* (http://monco.frazeo.pl/)
*Pracowaliśmy **full time**.*
*Jestem cała **happy**!* (Zasłyszane)
*Mój profil został odwiedzony 58 razy w jeden dzień! Widzę, że mam całkiem dużo podglądaczy. **LOL!*** (Zasłyszane)

2.3. Potrzeba szybkiej komunikacji jest najprawdopodobniej powodem **cięć morfologicznych** dość charakterystycznych w polskiej komunikacji współczesnej. Cięcia morfologiczne widoczne są w języku polskim, np. w takich słowach jak: *wykon* (wykonanie), *graty* (gratulacje), *szacun* (szacunek), *ta* (tak), *osiąg / osiągi* (osiągnięcie / osiągnięcia), *akcept* (akceptować), *spontan* (coś dziejącego się spontanicznie) i ich wariantach derywacyjnych, np. *kom* / *koma* (komórka, telefon komórkowy).

Przykłady użyć:

– *Poraził mnie ten **spontan** ludzi.* (http://monco.frazeo.pl/)
– *Lśniący wóz prosto z salonu, **klima**, 320 koni, a jazda kosztuje jedyne 2,40 zł.* (http://monco.frazeo.pl/)
– *Nie mam przy sobie **kompa**, ale nie martw się, mam to wszystko na **penie**.* (http://korpusy.net/korpusy-jezyka-polskiego/korpus-pelcra.html)

W języku bułgarskim cięcia morfologiczne, choć obecne, występują znacznie rzadziej, niż ma to miejsce w języku polskim, do takich wniosków prowadzi analizowany różnorodny materiał językowy. Przykładami wykorzystywanych w języku bułgarskim ucięć są, np. *инфо* (информация), *комп* (компютър), *комбо* (комбирано), *хай* (хайтек).

Bułgarzy wciąż pytają „długo”, np. *Как си? Как е? Как върви? Как е хавата? Какво ново?* Od lat używane są słowa *здравей* lub *здрасти*. Poza żargonowym terminami nie funkcjonują ekwiwalentne skróty jak *narka* itd. Z obserwacji współczesnej leksyki bułgarskiej wynika, że nie ma w bułgarszczyźnie wielu ucięć, w komunikacji potocznej zamiast nich cierpliwie wymawiane lub zapisywane są całe wyrazy.

Przykłady użyć:

***Споко / Спокс** човече! Можеш да говориш това, което мислиш, и какво искаш*. (РНДБЕ 2010)
*Прибирам се в къщи да си играйкам на **компа** в къщи*. (http://search.dcl.bas.bg/)

2.4. Do współczesnego polskiego i bułgarskiego języka ogólnego absorbowana jest **terminologia specjalistyczna** – głównie techniczna, ale również medyczna, sportowa, ekonomiczna. **Język**

techniczny,[6] szczególnie **informatyczny**, reprezentowany jest we współczesnym języku polskim i języku bułgarskim głównie za sprawą popularności Internetu, komunikatorów i portali internetowych i samego oprzyrządowania. W wielu przypadkach podczas asymilowania do języka nowych słów dochodzi do pełnych zapożyczeń – graficznych, nie tylko fonetycznych. Por. następujące przykłady jednych i drugich: pol. *chip*, bułg. *чип* (od ang. *chip*); pol. *czat lub chat*, bułg. *чат* (od ang. *chat*); pol. *webmaster*, bułg. *уебмастер* lub *уебмастър* (od ang. *webmaster*); pol. *crack*, bułg. *крак* lub *крек* (od ang. *crack*); pol. *iPhone*, bułg. *айфон*; pol. *iPod*, bułg. *айпод*.

2.5. Do najbardziej charakterystycznych polskich i bułgarskich tendencji językowych ostatnich lat zaliczyć należy **często tworzone skrótowce**. Ich wyjątkowa aktywność zdaniem Małgorzaty Urban ma związek z faktami pozajęzykowymi: „Po 1989 roku wzmogło się życie polityczne i gospodarcze kraju, powstały nowe partie, organizacje i firmy. Wolność słowa sprawiła, że dynamizacji uległ język polityki wypowiedzi prasowych. Wielu badaczy, między innymi Władysław Lubaś [Lubaś 2003], Alicja Nagórko [Nagórko 2003] i Halina Satkiewicz [Satkiewicz 1992], podkreśla, że towarzysząca temu emocjonalizacja dyskursu wpłynęła na zmniejszenie się dystansu między językiem ogólnym a potocznym […]" (Urban 2007: 360–361).
Ilustrację skrótów i tworzonych od nich derywatów stanowić mogą następujące polskie przykłady: PIS > *pisowiec*, *pisior*; PR > *piarowiec*; BMW > *beemka*, *beema*; TIR > *tirówka*, *tirowiec* itp. Neologizmy rzeczownikowe wywodzone od skrótowców mogą być tworzone od podstaw rodzimych i obcych, z wykorzystaniem formantów rodzimych.

3.0. Podsumowanie

Specjalne funkcje monitorowania nowych słów, użyć, bieżące aktualizacje poprawiają warunki pracy nad neologizmami, neosemantyzmami i zapożyczeniami, które, jak wskazują nakreślone w artykule tendencje języków słowiańskich (na przykładzie języka polskiego i bułgarskiego), nieustannie zmieniają „kształt" współczesnych języków. Im bardziej zrównoważony tematycznie i gatunkowo korpus, tym lepiej dla korzystających z niego poszukiwaczy. We współczesnych korpusach, dzięki nowoczesnym wyszukiwarkom (takim jak np. www.monco.frazeo.pl[7] – 2400 milionów segmentów słów) wyniki zapytań korpusowych można wizualizować i eksportować w postaci np. arkuszy MS Excel. Specjalny moduł ekstrakcji kolokacji umożliwia badanie łączliwości wyrazów dla jedno- i wielowyrazowych zapytań. Analogiczne narzędzie jest od pewnego czasu dostępne dla danych angielskich (monitorcorpus.com).

---

[6] Używany coraz częściej w komunikacji codziennej język techniczny podlega modyfikacjom, również żartobliwym. Przykładem popularnego i pochodzącego z języka technicznego ironicznego terminu jest polskie słowo *gadować* (wraz z jego wariantami fleksyjnymi) od komunikatora *gadu-gadu* (w skrócie *gg)*.

[7] Aktualny opis funkcji wyszukiwarki można znaleźć na stronie pomocy: http://monco.frazeo.pl/help.

3.1. W przypadku badań konfrontatywnych ogromną rolę spełniają korpusy równoległe analizowanych języków. Dla języka polskiego i bułgarskiego dobrym źródłem informacji jest tworzony przez językoznawców z Instytutu Slawistyki PAN w Warszawie *Równoległy korpus polsko-bułgarsko-rosyjski*[8] stanowiący doświadczenie, zdobyte wcześniej przy okazji *Eksperymentalnego, równoległego korpusu polsko-bułgarsko-rosyjskiego*. Wypracowana wcześniej metodyka konstruowania korpusów wymaga jednak pewnych dalszych udoskonaleń. Efekty dotychczasowej pracy dostępne są na stronie *Równoległego korpusu polsko-bułgarsko-rosyjskiego* (https://clarin-pl.eu/dspace/handle/11321/308).

3.2. „Ekscerpcja i badania najmłodszej leksyki w oparciu o korpusy językowe, a także analiza współczesnych słowiańskich tendencji językowych muszą być realizowane w związku z kilkoma istotnymi kryteriami i dotyczyć.: (1) znacznej reprezentacji w korpusie różnych warstw stylistycznych języka, (2) wielości badanego materiału, (3) reprezentatywności ilościowej (frekwencji) ekscerpowanych i badanych jednostek, w celu wykluczenia np. okazjonalizmów, (4) uwzględnienia szeroko pojętego kontekstu, (5) osadzenia materiału językowego we współczesnym języku i, co bardzo istotne, zdefiniowaniu na rzecz prowadzonych badań terminu *neologizm* (bo jak wiadomo z licznych opracowań termin *neologizm* ma różny dla badaczy zakres znaczeniowy i używany jest w różnych pracach językoznawczych wymiennie z innymi określeniami)[9], (6) dowodów na akceptację neologizmu w systemie języka naturalnego”.[10]

3.3. Wyłącznie sygnalizowane w tym artykule i dotyczące języka polskiego i bułgarskiego współczesne tendencje językowe takie jak **potocyzacja**, **brutalizacja**, **wulgaryzacja**, **skrótowość wypowiedzi**, **emocjonalność**, **duża przyswajalność anglojęzycznych terminów i sensów** (*dokładnie, kultowy*), **trywialność wypowiedzi** (często **infantylność**, np. w reklamach) i ich **niejednorodność stylistyczna** są charakterystyczne dla wszystkich języków słowiańskich (świadczą o tym liczne przykłady z korpusów poszczególnych języków czy korpusów paralelnych). Ich realizacja w poszczególnych językach odbywa się z różnym natężeniem, ale jest bezsprzecznie zauważalna i charakteryzowana przez językoznawców w obrębie poszczególnych języków, np. „oswajanie” anglojęzycznych terminów obserwowane w języku polskim i bułgarskim wydaje się nieco silniejsze w niektórych dziedzinach w języku bułgarskim (Satoła-Staśkowiak 2013b; 2015a:

---

[8] Autorami korpusu są: Maksim Duškin, Danuta Roszko, Roman Roszko, Joanna Satoła-Staśkowiak, Wojciech Sosnowski, Roman Tymoshuk (wcześniej w projekcie udział brali: Anna Kisiel, Natalia Kotsyba i Violetta Koseska-Toszewa). Por. https://clarin-pl.eu/dspace/handle/11321/308; http://ispan.waw.pl/default/pl/projekty-naukowe/215-clarin.

[9] Np. *nowotwory* (por. Buttler 1962), *nowe słownictwo, najnowsza leksyka, najmłodsza leksyka,* itd. (por. Satoła-Staśkowiak 2015a), *neologizmy absolutne* (por. Grabias 1981), *typowe i pozasystemowe neologizmy* (Puzynina 1966). Rozumiany jest różnie – inaczej przez badaczy języka, a inaczej przez badaczy literatury. W językoznawstwie *neologizmy* tradycyjne są przedstawiane jako jedna z odmian innowacji językowej (por. Rospond 1945: 97–105). Do tej samej grupy obok neologizmów należą innowacje fonetyczne, fonologiczne, fleksyjne i składniowe (por. Chomik – Krajewska 2011: 11).

[10] Satoła-Staśkowiak, J. *Badania nad najmłodszą leksyką słowiańska w oparciu o korpusy językowe* (w druku).

31–50). Jako ilustrację tej tezy warto przytoczyć takie bułgarskie przykłady jak *даунлоуд*, *даунлоудвам*, *даунлоудна*, *даунлоудване*, *даунлоудър* (wszystkie od ang. *download*), *атачмънт* (od ang. *attachment*), *ъпгрейдване* (od ang. *upgrade*), *браузър* (od ang. *browser*), *блогатон* (od ang. *blogathon*), które w Polsce mimo popularności Internetu i języka angielskiego (a właściwie amerykańskiej jego wersji) nadal mają „swojsko", bo polsko brzmiące nazwy: *pobierz*, *pobierać*, *pobrać*, *pobieranie*, *załącznik*, *aktualizacja (programu komputerowego)*, *przeglądarka*, lub, jak w przypadku dwóch ostatnich nazw bułgarskich, jeszcze nie posiadają nazwy i określane są w sposób opisowy, jak: 'osoba pobierająca dane z sieci – *żarg.* ssacz', 'maraton internetowy z udziałem wielu uczestników publikujących informacje na określonej stronie internetowej' (Satoła-Staśkowiak 2013c). Opisywana tu dysproporcja jest niewielka i dotyczy głównie słownictwa informatycznego.

3.4. Wśród wielu zalet korpusów językowych (języków mówionych i pisanych) korpusów konfrontatywnych i wykorzystywanych przez nie wyszukiwarek do najważniejszych należy oszczędność czasu badacza i możliwości prześledzenia znacznych partii zrównoleglonego materiału w znacznie krótszym, niż podczas „tradycyjnych" badań, terminie.

Bibliografia:

Bańko – Czeszewski – Burzyński: Bańko, M. – Czeszewski, M. – Burzyński, J. (red.). *Obserwatorium Językowe Uniwersytetu Warszawskiego, Najnowsze Słownictwo Polskie* [online]. [cit. 10.09.2016] <http://nowewyrazy.uw.edu.pl/projekt.html>

Buttler 1962: Buttler D., Neologizm i terminy pokrewne, [w:] „*Poradnik Językowy*", z. 5, 6, s. 239 –251.

Chomik – Krajewska 2011: Chomik, M. – Krajewska, M. *Od nominacji do kreacji: rzecz o przekładzie neologizmów science fiction*. Toruń.

Grabias 1981: Grabias S., *O ekspresywności języka. Ekspresja a słowotwórstwo*, Lublin.

Kudra 2001: Kudra, B. *Kreatywność leksykalna w dyskursie politycznym polskiej prasy lat osiemdziesiątych i dziewięćdziesiątych*. Łódź.

Lubaś 2003: Lubaś, W. *Polskie gadanie. Podstawowe cechy i funkcje potocznej odmiany polszczyzny*, Opole.

Nagórko 2003: Nagórko A. *Różnicowanie i unifikacja środków słowotwórczych w służbie* , In: I. Ohnheiser (red.), *Komparacja współczesnych języków słowiańskich. Słowotwórstwo/Nominacja*, Opole, s. 217–233

Puzynina 1966: Puzynina, J. *O potencjalnych formacjach słowotwórczych, „Poradnik językowy"*, z. 8, s. 329–338.

РНДБЕ 2010: Пернишка Е., Благоева Д., Колковска С., 2010, *Речник на новите думи в българския език*, София.

Rospond 1945: Rospond S., Nowotwory czy nowopotwory językowe, In: „*Język Polski*", z. 4, s. 97 –105.

Satkiewicz 1992: Satkiewicz H. *O kulturę słowa w Polsce*, „*Poradnik Językowy*" 1992, z. 8, s. 603-604.

Satoła-Staśkowiak 2013a: Satoła-Staśkowiak, J. Contemporary Contrastive Studies of Polish, Bulgarian and Russian Neologisms versus Language Corpora. – *Cognitive Studies/Études Cognitives 13*, 143–160.

Satoła-Staśkowiak 2013b: Satoła-Staśkowiak, J. Neologizmy bułgarskie, polskie i rosyjskie w ujęciu konfrontatywnym. In: *Проблеми на неологията в славянските езици* (eds. Д. Благоева, С. Колковска, М. Лишкова). София: БАН, 21–30.

Satoła-Staśkowiak 2013c: Satoła-Staśkowiak, J. Polskie i bułgarskie neologizmy znaczeniowe, In: *Проблеми на неологията в славянските езици* (eds. Д. Благоева, С. Колковска, М. Лишкова). София: БАН, 218–230.

Satoła-Staśkowiak 2015a: Satoła-Staśkowiak, J. *Najmłodsza leksyka polska i bułgarska*. Warszawa: SOW.

Satoła-Staśkowiak 2015b: Satoła-Staśkowiak, J. On the benefits of foreign language learning based on parallel language corpus. – *Cognitive Studies/Études Cognitives 15*, 57–65.

Satoła-Staśkowiak 2016: Satoła-Staśkowiak, J. O anglizowaniu wymowy w polskich i bułgarskich w wypowiedziach młodych ludzi. In: *За словото – нови търсения и подходи.* Юбилеен сборник в чест на чл.-кор. проф. д.ф.н. Емилия Пернишка (състав. и ред. Д. Благоева, С. Колковска). София: Академично издателство Проф. Марин Дринов, 180–184.

Urban 2007: Urban, M. Rzeczownikowe derywaty od skrótowców w najnowszej polszczyźnie. In: *Z zagadnień leksykologii i leksykografii języków słowiańskich* (eds. J. Kamper-Warejko, I. Kaproń-Charzyńska). Toruń, 355–362.

Waszakowa 1994: Waszakowa, K. Tendencje rozwojowe w słowotwórstwie polszczyzny końca XX wieku. In: *Przemiany współczesnej polszczyzny* (ed. S. Gajda). Opole, 53–60.

Waszakowa 2011: Waszakowa, K. Polszczyzna przełomu XX i XXI wieku: dynamika procesów sprzyjających internacjonalizacji. In: *Исследования по славянским языкам*, 16–1. Сеул, 125–142.