JĘZYKOZNAWSTWO KORPUSOWE

SPOTKANIE III

JOANNA SATOŁA-STAŚKOWIAK

CZYM JEST JĘZYKOZNAWSTWO KORPUSOWE?

- WEDŁUG BARBARY LEWANDOWSKIEJ-TOMASZCZYK JĘZYKOZNAWSTWO KORPUSOWE: JEST JEDNĄ Z CZĘŚCI JĘZYKOZNAWSTWA KOMPUTEROWEGO I ZAJMUJE SIĘ ANALIZĄ JĘZYKA ZGROMADZONEGO W KORPUSACH JĘZYKOWYCH, CZYLI KOMPUTEROWYCH ZBIORACH AUTENTYCZNYCH TEKSTÓW JĘZYKOWYCH, MÓWIONYCH I PISANYCH (LEWANDOWSKA-TOMASZCZYK 2005: 11).
- ZBIORU TEKSTÓW NIE MOŻNA ZATEM UZNAĆ ZA KORPUS, JEŚLI NIE MOŻNA GO ZAPISAĆ W SPOSÓB ELEKTRONICZNY I W TEN SAM SPOSÓB ODCZYTYWAĆ. INACZEJ MÓWIĄC – W TYM UJĘCIU ZBIORÓW TEKSTÓW ZGROMADZONYCH PRZED WPROWADZENIEM DO JĘZYKOZNAWSTWA KOMPUTERÓW NIE NALEŻY OKREŚLAĆ MIANEM KORPUSÓW.

CZYM JEST JĘZYKOZNAWSTWO KORPUSOWE?

- JEDNYM Z PIERWSZYCH PODRĘCZNIKÓW JĘZYKOZNAWSTWA KORPUSOWEGO BYŁ AARTS I MEIJS (1984), CHOCIAŻ POJĘCIE TO ZOSTAŁO UŻYTE JUŻ WCZEŚNIEJ, NA PRZYKŁAD W AARTS I VAN DEN HEUVEL (1982). PONADTO W LITERATURZE ANGIELSKOJĘZYCZNEJ STOSUJE SIĘ TAKŻE (POR. TAYLOR 2008, SZCZEGÓŁOWA ANALIZA WYSTĘPOWANIA NAZW DYSCYPLINY W PUBLIKACJACH NAUKOWYCH) POJĘCIA CORPUS/CORPUS-BASED/CORPUS-DRIVEN/CORPUS ASSISTED + ANALYSIS/APPROACH/STUDY, A TAKŻE WYODRĘBNIA CORPUS-DRIVEN LINGUISTICS (TOGNINI-BONELLI 2001).

CZYM JEST JĘZYKOZNAWSTWO KORPUSOWE?

- NALEŻY PONADTO PAMIĘTAĆ, ŻE MIMO OGROMNEGO POSTĘPU TECHNOLOGICZNEGO W WIELU ASPEKTACH BADAŃ KORPUSOWYCH INGERENCJA CZŁOWIEKA JEST NIEODZOWNA (NA PRZYKŁAD W WERYFIKACJI ANALIZY MORFOLOGICZNEJ I SKŁADNIOWEJ). PODOBNEGO ZDANIA SĄ MCENERY I WILSON (1996: 1), KTÓRZY PODAJĄ NIEWĄTPLIWIE MNIEJ, A NAWET ZUPEŁNIE NIENAUKOWĄ, ZA TO SZERSZĄ I NASZYM ZDANIEM ZDROWOROZSĄDKOWĄ DEFINICJĘ JĘZYKOZNAWSTWA KORPUSOWEGO JAKO „BADANIE JĘZYKA W OPARCIU O RZECZYWISTE PRZYKŁADY JEGO UŻYCIA". (POR. TAKŻE ELEMENTY JĘZYKOZNAWSTWA KORPUSOWEGO W BIBER ET AL. 1998.)

CZYM JEST JĘZYKOZNAWSTWO KORPUSOWE?

- W BADANIACH KORPUSOWYCH KOMPUTER JEST NADAL JEDYNIE NARZĘDZIEM, KTÓRE UMOŻLIWIA BADANIE I OPISYWANIE TEGO, CO JEST. TECHNOLOGIA ZATEM NIE WYZNACZA POCZĄTKU BADAŃ, A JEDYNIE – I AŻ – JAKOŚCIOWO ORAZ ILOŚCIOWO ZMIENIA SPOSÓB ICH PROWADZENIA. PONADTO NIEWĄTPLIWIE OBECNIE KAŻDY KORPUS JEST ZBIOREM KOMPUTEROWYM, A NAWET KORPUSY STARSZE – POCZĄTKOWO DOSTĘPNE JEDYNIE W WERSJI PAPIEROWEJ – DOCZEKAŁY SIĘ PRZETWORZENIA DO FORMATU ELEKTRONICZNEGO (NA PRZYKŁAD KORPUS ZGROMADZONY W RAMACH PROJEKTU SURVEY OF THE ENGLISH LANGUAGE).

HISTORIA BADAŃ KORPUSOWYCH

- JĘZYKOZNAWSTWO KORPUSOWE WE WSPÓŁCZESNYM UJĘCIU, CZYLI WYKORZYSTUJĄCE TECHNOLOGIĘ CYFROWĄ, POJAWIŁO SIĘ W LATACH 50. UBIEGŁEGO WIEKU, ZAŚ NAJWIĘKSZY POSTĘP TEJ DYSCYPLINY ŁĄCZY SIĘ Z WPROWADZENIEM TZW. MIKROKOMPUTERÓW W LATACH SIEDEMDZIESIĄTYCH XX WIEKU ORAZ – W LATACH OSIEMDZIESIĄTYCH – DYSKÓW OPTYCZNYCH. OD TEGO MOMENTU WRAZ ZE WZROSTEM MOCY OBLICZENIOWEJ I ROZWOJEM OPROGRAMOWANIA – KTÓRE UMOŻLIWIAŁY SZYBKIE PRZETWARZANIE DANYCH ORAZ ICH SZCZEGÓŁOWĄ ANALIZĘ – ROZPOCZĄŁ SIĘ DUŻY ROZWÓJ W TEJ DZIEDZINIE BADAŃ JĘZYKOZNAWCZYCH.

HISTORIA BADAŃ KORPUSOWYCH (LATA `70 I KRYTYCYZM CHOMSKY`EGO)

- UPOWSZECHNIENIE KOMPUTERÓW W HISTORII JĘZYKOZNAWSTWA PRZYPADA NA LATA 70. UBIEGŁEGO WIEKU, TAK W SFERZE POSTRZEGANIA KORPUSU JAKO ŹRÓDŁA WIEDZY O JĘZYKU ISTOTNĄ CEZURĘ STANOWIĄ LATA 50. WTEDY TO – POD ZNACZNYM WPŁYWEM POGLĄDÓW N. CHOMSKY'EGO (1957: 1965) − JĘZYKOZNAWSTWO ZACZĘŁO ODWRACAĆ SIĘ OD EMPIRYZMU NA RZECZ RACJONALIZMU, CZYLI OD BADAŃ OPARTYCH NA RZECZYWISTYCH PRZYKŁADACH UŻYCIA JĘZYKA W STRONĘ DANYCH WYGENEROWANYCH PRZEZ BADACZA I JEGO WŁASNYCH OSĄDÓW, A WIĘC KOMPETENCJI JĘZYKOWEJ (WEWNĘTRZNYCH UMIEJĘTNOŚCI JĘZYKOWYCH) NIE ZAŚ PERFORMANCJI (JEJ UZEWNĘTRZNIENIA, CZYLI ZASTOSOWANIA JĘZYKA, KTÓRE NIE ZASŁUGUJE – PRZECIWNIE DO KOMPETENCJI – NA DOGŁĘBNE BADANIA); POR. CHOMSKY 1957, 1965.

HISTORIA BADAŃ KORPUSOWYCH

- STAN TEN MÓGŁ WYNIKAĆ Z PRZEŚWIADCZENIA NIEKTÓRYCH WCZESNYCH PRZEDSTAWICIELI JĘZYKOZNAWSTWA KORPUSOWEGO (M.IN. HARRIS 1951), ŻE JĘZYK JEST TZW. BYTEM SKOŃCZONYM, A ZATEM KORPUSY SĄ JEGO OBIEKTYWNYM I PEŁNYM OBRAZEM. KRYTYKA JĘZYKOZNAWSTWA KORPUSOWEGO BYŁA TYM ŁATWIEJSZA, ŻE PRZY SŁABOŚCI METOD NUMERYCZNYCH I TECHNOLOGII KOMPUTEROWEJ BARDZIEJ WSZECHSTRONNA I PRECYZYJNA ANALIZA KORPUSU BYŁA ZADANIEM NIEWYKONALNYM.

HISTORIA BADAŃ KORPUSOWYCH

- „Swój jednoznaczny krytycyzm wobec korpusu Chomsky uzasadniał tym, że „korpus nigdy nie stanie się narzędziem przydatnym językoznawcy, ponieważ zadaniem badacza jest stwarzanie modeli kompetencji językowej, a nie użycia języka", które w niewielkim stopniu odzwierciedla kompetencję (McEnery, Wilson 1996). Ponadto korpus nie stanowi obiektywnego odzwierciedlenia rzeczywistości językowej – „jest skończony i w pewnym sensie przypadkowy" (Chomsky 1957: 15) – która ma charakter nieskończony („przypuszczalnie nieskończony"; Chomsky 1957: 15), zatem nie można na jego podstawie formułować wniosków ogólnojęzykowych, ponieważ „rozważania probabilistyczne nie mają żadnego związku z gramatyką" (Chomsky 1964: 215). Ilustracją tego zagadnienia jest podawany przez Chomsky'ego przykład: zdanie I live in New York występuje w języku częściej niż zdanie I live in Dayton, Ohio z tej prostej przyczyny, że Nowy Jork ma więcej mieszkańców." (Paryzek, 2011:13)

HISTORIA BADAŃ KORPUSOWYCH

- Chomsky stwierdza ponadto, że „każdy korpus naturalny jest wypaczeniem rzeczywistości. Niektóre zdania nie występują w nim, ponieważ są oczywiste, inne, ponieważ są nieprawdziwe, zaś jeszcze inne, ponieważ byłyby nieuprzejme" (Chomsky 1957: 159). Badacz twierdzi wreszcie, że tylko 5% wypowiedzi użytkowników języka to wypowiedzi gramatyczne, reszta zaś jest gramatycznie niepoprawna, a więc badanie performancji (realnych użyć) nie ma sensu (Chomsky 1965). Zamiast niereprezentatywnego i skończonego korpusu źródłem prawdy o języku miałby być sam językoznawca, jego kompetencja językowa i introspektywne obserwacje dzięki umysłowi pozwalające ogarnąć większą liczbę wypowiedzi (McEnery, Wilson 1996: 9).

HISTORIA BADAŃ KORPUSOWYCH

- Krytycyzm wobec językoznawstwa korpusowego wyrażał ponadto Abercrombie (1965), który – w przeciwieństwie do Chomsky'ego – skupiał się na kwestiach o charakterze praktycznym, takich jak pracochłonność i czasochłonność badań oraz ich podatność na błędy związana z zaangażowaniem wielu nieraz tysięcy osób opracowujących materiał językowy.
- Jednoznaczny krytycyzm Chomsky'ego i podważanie użyteczności korpusów w ogóle doprowadziły do spadku zainteresowania badaniami korpusowymi, jednak nie spowodowały ich wygaśnięcia. Nadal prowadzono analizy w dziedzinie fonetyki, w której użyteczność danych rzeczywistych trudniej było podważyć, w badaniach akwizycji języka ojczystego przez dzieci, ponieważ w tym przypadku – z uwagi na wiek użytkownika języka – informacji introspektywnych nie można było uzyskać oraz w językoznawstwie historycznym, w przypadku którego także nie było możliwości skorzystania z wiedzy o kompetencji językowej.