JĘZYKOZNAWSTWO KORPUSOWE

Spotkanie V

Joanna Satoła-Staśkowiak

KORPUSY HISTORYCZNE I WSPÓŁCZESNE

- Wraz z postępem w badaniach w dziedzinie językoznawstwa korpusowego zwiększa się także liczba zbiorów źródłowych, zarówno prywatnych, jak i dostępnych dla szerszej liczby badaczy poprzez Internet (zwykle darmowe są jedynie wersje demonstracyjne, wersja pełna jest płatna – na przykład Bank of English) lub na nośnikach optycznych. Korzystać można ze zbiorów interesujących poznawczo lub egzotycznych, np. wszystkich przemówień inauguracyjnych prezydentów Stanów Zjednoczonych, ogromnego korpusu mannheimskiego (kilkaset milionów wyrazów, http://www.ids-mannheim.de/kl/corpora.html) oraz korpusu języka staro- i średniofrancuskiego; więcej przykładów na stronie http://www.athel.com/corpus.html).
-

KORPUSY ERY PRZEDKOMPUTEROWEJ

- Przed wprowadzeniem do korpusologii komputerów, co nastąpiło w początkach lat 60. XX wieku, badania korpusowe prowadzono w szeregu obszarów (Kennedy 1998: 13):

1. Teksty biblijne i literackie
2. Ortografia

- Kaeding (1897) wykorzystał ogromny jak na ówczesne standardy, złożony z około 11 milionów wyrazów korpus do określenia częstotliwości występowania liter i ciągów liter (przedrostków, tematów i przyrostków) w języku niemieckim. Studium miało służyć usprawnieniu systemu notacji stenograficznej, stąd litery i ich ciągi odpowiadały znakom stenograficznym. W pracę tę zaangażowano około 5000 ochotników.

KORPUSY ERY PRZEDKOMPUTEROWEJ C.D.

3. LEKSYKOGRAFIA

- JEDNA Z PRZEŁOMOWYCH PRAC W HISTORII LEKSYKOGRAFII TO WYDANY W 1755 R. SŁOWNIK JĘZYKA ANGIELSKIEGO SAMUELA JOHNSONA. W PRZECIWIEŃSTWIE DO PUBLIKACJI WCZEŚNIEJSZYCH JOHNSON – ZGODNIE Z ZAŁOŻONYM WCZEŚNIEJ PLANEM (JOHNSON 1747) – ZGROMADZIŁ PONAD 150 TYSIĘCY CYTATÓW Z TEKSTÓW LITERACKICH I NA ICH PRZYKŁADZIE OPISYWAŁ ZNACZENIE ORAZ UŻYCIE 40 TYSIĘCY WYRAZÓW HASŁOWYCH (POR. REDDICK 1990, HITCHINGS 2005, HANKS 2005, LANDAU 2005). PONADTO BADANIA KORPUSOWE WYKORZYSTYWANO DO STUDIÓW NAD DIALEKTAMI, CZEGO WYNIKIEM BYŁY THE EXISTING PHONOLOGY OF ENGLISH DIALECTS (ELLIS 1889) ORAZ ENGLISH DIALECT DICTIONARY (WRIGHT 1905). PODOBNIE OXFORD ENGLISH DICTIONARY Z ROKU 1928 ZOSTAŁ OPRACOWANY NA PODSTAWIE FISZEK Z CYTATAMI Z LITERATURY (W 1882 R., CZYLI NA DWA LATA PRZED OPUBLIKOWANIEM PIERWSZEGO TOMU, ZGROMADZONO ICH 3,5 MILIONA), KTÓRE RAZEM OBEJMOWAŁY KILKADZIESIĄT MILIONÓW WYRAZÓW; PATRZ MUGGLESTONE 2005 ORAZ PRACA, W KTÓREJ PORÓWNANO PODEJŚCIE DO TWORZENIA SŁOWNIKA ZASTOSOWANE W DZIELE JOHNSONA I OXFORD ENGLISH DICTIONARY (SILVA 2005).

KORPUSY ERY PRZEDKOMPUTEROWEJ C.D.

4. GRAMATYKA

- KORPUS MOŻE BYĆ PODSTAWOWYM ŹRÓDŁEM DANYCH, NA PODSTAWIE KTÓREGO OPRACOWUJE SIĘ GRAMATYKI OPISOWE.
- JEDNĄ Z NAJWAŻNIEJSZYCH PÓŹNIEJSZYCH PRAC TEGO RODZAJU BYŁ SURVEY OF ENGLISH USAGE (QUIRK 1968). PODSTAWOWYM CELEM KORPUSU BYŁO UZYSKANIE DANYCH, NA PODSTAWIE KTÓRYCH MOŻNA BY OPISAĆ GRAMATYKĘ WYKORZYSTYWANĄ PRZEZ DOROSŁYCH, WYKSZTAŁCONYCH (CO WPŁYNĘŁO NA CHARAKTER TEKSTÓW – STOSUNKOWO OFICJALNY, CZĘSTO AKADEMICKI) UŻYTKOWNIKÓW BRYTYJSKIEJ ODMIANY JĘZYKA ANGIELSKIEGO. BADANIA ROZPOCZĘTO W 1959 R., GROMADZĄC TEKSTY PISANE (INFORMACYJNE, SZKOLENIOWE, KORESPONDENCJĘ, DZIENNIKI, SZTUKI TEATRALNE) ORAZ NAGRANIA (MONOLOGI, DIALOGI, AUDYCJE RADIOWE, PRZEMÓWIENIA, ROZMOWY TELEFONICZNE), KTÓRE NASTĘPNIE TRANSKRYBOWANO I ZAPISYWANO NA PAPIEROWYCH FISZKACH. NIEZWYKLE ISTOTNE JEST TO, ŻE DĄŻONO DO RÓWNOWAGI TEKSTÓW MÓWIONYCH I PISANYCH. W TEN SPOSÓB ZGROMADZONO 200 TEKSTÓW PO 5000 WYRAZÓW KAŻDY (ZGODNIE Z WCZEŚNIEJ WSPOMNIANYMI ZAŁOŻENIAMI KUČERY I FRANCISA). WSZYSTKIE TEKSTY ADNOTOWANO, DODAJĄC DOKŁADNY OPIS GRAMATYCZNY. OBECNIE KORPUS JEST JUŻ CAŁKOWICIE SKOMPUTERYZOWANY, BĘDĄC PRZYKŁADEM EWOLUCJI ZBIORU TEKSTÓW POWSTAŁEGO PRZED ZASTOSOWANIEM W JĘZYKOZNAWSTWIE KOMPUTERÓW. NA PODSTAWIE BADAŃ WYDANO REFERENCYJNĄ GRAMATYKĘ17 JĘZYKA ANGIELSKIEGO A COMPREHENSIVE GRAMMAR OF THE ENGLISH LANGUAGE (QUIRK ET AL. 1985). INFORMACJE NA TEN TEMAT ZNALEŹĆ MOŻNA TAKŻE W: HUNSTON, FRANCIS 2000, LEWANDOWSKA-TOMASZCZYK ET AL. 2001.

WYBRANE KORPUSY KOMPUTEROWE

BROWN CORPUS

- PIERWSZYM KORPUSEM KOMPUTEROWYM BYŁ ZBIÓR TEKSTÓW KUČERY I FRANCISA POWSTAŁY W ROKU 1967 (KUČERA I FRANCIS, 1967) – BROWN UNIVERSITY STANDARD CORPUS OF PRESENT-DAY AMERICAN ENGLISH (ZNANY BARDZIEJ JAKO BROWN CORPUS), KTÓRY – CHOĆ NIEWIELKI JAK NA DZISIEJSZE WARUNKI – BYŁ W TYCH CZASACH DZIEŁEM PRZEŁOMOWYM. POWSTAŁ ON W OKRESIE NIEŁATWYM DLA JĘZYKOZNAWSTWA KORPUSOWEGO, NAZNACZONYM KRYTYCYZMEM CHOMSKY'EGO (PATRZ ROZDZIAŁ 2, PUNKT 1.1). SKŁADAŁ SIĘ Z TEKSTÓW POWSTAŁYCH W STANACH ZJEDNOCZONYCH W ROKU 1961 (ZAWIERAŁ 500 PRÓBEK PO 2000 WYRAZÓW), NALEŻĄCYCH DO 15 GATUNKÓW LITERACKICH (TEKSTY PRASOWE, W TYM REPORTAŻE, ARTYKUŁY REDAKCYJNE I RECENZJE, RELIGIJNE, HOBBISTYCZNE, POPULARNE, LITERATURA PIĘKNA, NAUKOWE, BELETRYSTYKA, W TYM LITERATURA NAUKOWA, PRZYGODOWA, ROMANTYCZNA, FANTASTYKA NAUKOWA I HUMOR). CO CIEKAWE, PIERWSZA WERSJA KORPUSU ZAPISANA BYŁA NA KARTACH PERFOROWANYCH, ZAŚ NA PRZYKŁAD WIELKIE LITERY OZNACZONO GWIAZDKĄ. WEDŁUG TEUBERTA (2004) TO WŁAŚNIE FRANCIS JAKO PIERWSZY ZASTOSOWAŁ TERMIN „KORPUS" DO OKREŚLENIA ELEKTRONICZNEGO ZBIORU TEKSTÓW.

WYBRANE KORPUSY KOMPUTEROWE

BRITISH NATIONAL CORPUS

- KORPUS TEN JEST ZBIOREM TEKSTÓW MÓWIONYCH I PISANYCH BRYTYJSKIEJ ODMIANY JĘZYKA ANGIELSKIEGO Z KOŃCA WIEKU XX. JEST TO KORPUS MONOLINGWALNY, SYNCHRONICZNY, OGÓLNY, PRÓBKOWANY (W PRZYPADKU TEKSTÓW PISANYCH GROMADZI SIĘ FRAGMENTY O DŁUGOŚCI DO 45 TYSIĘCY WYRAZÓW, CO UMOŻLIWIA OSIĄGNIĘCIE WIĘKSZEJ REPREZENTATYWNOŚCI). KORPUS NIE JEST ZRÓWNOWAŻONY POD WZGLĘDEM TEKSTÓW PISANYCH I MÓWIONYCH (ODPOWIEDNIO 90% I 10%), PRZY CZYM TEKSTY PISANE OBEJMUJĄ ARTYKUŁY PRASOWE (OGÓLNE I SPECJALISTYCZNE), PODRĘCZNIKI, LITERATURĘ PIĘKNĄ, LISTY, WYPRACOWANIA I INNE, ZAŚ CZĘŚĆ MÓWIONA ZAWIERA SWOBODNE KONWERSACJE NAGRYWANE PRZEZ OCHOTNIKÓW, A TAKŻE MAJĄCE ZDECYDOWANIE BARDZIEJ OFICJALNY CHARAKTER PRZEMÓWIENIA (DEBATY POLITYCZNE, KAZANIA) ORAZ NAGRANIA AUDYCJI RADIOWYCH I PROGRAMÓW Z UDZIAŁEM SŁUCHACZY.
- KORPUS JEST CAŁKOWICIE ADNOTOWANY ZGODNIE ZE STANDARDEM TEI18. ZAWIERA INFORMACJE O CZĘŚCIACH MOWY ADNOTOWANE PRZEZ AUTOMATYCZNY TAGGER CLAWS (GARSIDE 1987) ORAZ DANE METATEKSTOWE (NAGŁÓWKI, PODZIAŁ NA PARAGRAFY ITD.). CAŁKOWITA WIELKOŚĆ KORPUSU TO 100 MILIONÓW WYRAZÓW W 4054 TEKSTACH ZAJMUJĄCYCH OKOŁO 1,5 GB PAMIĘCI DYSKOWEJ. GROMADZENIE ROZPOCZĘTO W 1991 R. I ZAKOŃCZONO W ROKU 1994, ZAŚ PIERWSZE WYDANIE OGÓLNE KORPUSU POJAWIŁO SIĘ ROK PÓŹNIEJ. W ROKU 2007 OPUBLIKOWANO WYDANIE TRZECIE BNC XML EDITION. WYDANIE TO JEST DOSTĘPNE NA DVD OBOK KORPUSU BNC BABY ZAWIERAJĄCEGO CZTERY MILIONY WYRAZÓW. INTERESUJĄCE JEST TO, ŜE OBA WYDANIA ZAWIERAJĄ TAKŻE WERSJĘ KORPUSU ODMIANY AMERYKAŃSKIEJ JĘZYKA ANGIELSKIEGO BROWN CORPUS W FORMACIE XML.

WYBRANE KORPUSY KOMPUTEROWE

American National Corpus

- Ponieważ odmiany języka angielskiego brytyjska i amerykańska znacznie – i coraz bardziej – się różnią (Kachru 1982, Algeo 2006, Peters 2004, Trudgill, Hannah 2002), konieczne było stworzenie samodzielnego korpusu angielszczyzny amerykańskiej, wzorowanego zresztą na korpusie brytyjskim BNC. W planach jest stworzenie korpusu zasadniczego zawierającego przynajmniej 100 milionów słów pisanej i mówionej odmiany języka, obejmującego różnorodne rodzaje tekstów, w tym gatunki, które pojawiły się użyciu niedawno, np. blogi, listy elektroniczne i czaty. Pierwsze wydanie korpusu liczące ponad 11 milionów słów ukazało się w roku 2003. Korpusowi zasadniczemu będzie towarzyszyć dodatkowy zbiór tekstów zawierający kilkaset milionów słów i oferujący szerokie spektrum danych (Fillmore 1998, Ide 2001, 2004).

WYBRANE KORPUSY KOMPUTEROWE

COBUILD, BANK OF ENGLISH

- JEST TO KORPUS MONITORUJĄCY, ZAWIERAJĄCY OBECNIE 524 MILIONÓW SŁÓW.
- POCZĄTKOWO PROJEKT BYŁ PROWADZONY W RAMACH WSPÓŁPRACY WYDAWNICTWA COLLINS I WYDZIAŁU JĘZYKA ANGIELSKIEGO UNIWERSYTETU W BIRMINGHAM JAKO COLLINS BIRMINGHAM UNIVERSITY INTERNATIONAL LANGUAGE DATABASE (COBUILD). NA JEGO PODSTAWIE MIANO OPRACOWAĆ NOWY SŁOWNIK JĘZYKA ANGIELSKIEGO, DLATEGO TEŻ KORPUS „MIAŁ ODPOWIADAĆ POTRZEBOM UCZĄCYCH SIĘ JĘZYKA, NAUCZYCIELI I INNYCH UŻYTKOWNIKÓW, A TAKŻE STANOWIĆ WARTOŚCIOWE ŹRÓDŁO INFORMACJI DLA BADACZY ZAJMUJĄCYCH SIĘ WSPÓŁCZESNYM JĘZYKIEM ANGIELSKIM" (RENOUF 1987: 3). KORPUS ZAWIERAŁ JEDYNIE JEDNĄ CZWARTĄ TEKSTÓW MÓWIONYCH, Z NACISKIEM NA TEKSTY O CHARAKTERZE OGÓLNYM I NATURALNE UŻYCIE JĘZYKA, GŁÓWNIE BRYTYJSKIE, Z MNIEJSZYM UDZIAŁEM AMERYKAŃSKICH. W ROKU 1982 ZAWIERAŁ 7,3 MILIONA WYRAZÓW (KENNEDY 1998: 46), ZAŚ OBECNIE – JUŻ JAKO BANK OF ENGLISH – MIEŚCI 524 MILIONÓW WYRAZÓW I JAKO KORPUS MONITORUJĄCY JEST STALE ROZBUDOWYWANY. Z GROMADZENIEM TAK OGROMNEJ LICZBY DANYCH WIĄZAŁY SIĘ ZRESZTĄ PEWNE PROBLEMY (BLACKWELL 1993), TAKIE JAK ROZPOWSZECHNIONA WÓWCZAS NIEKOMPATYBILNOŚĆ OPROGRAMOWANIA I SPRZĘTU KOMPUTEROWEGO ORAZ BŁĘDY TYPOGRAFICZNE.

WYBRANE KORPUSY KOMPUTEROWE

INTERNATIONAL CORPUS OF ENGLISH (ICE)

- ZADANIEM TEGO KORPUSU (GREENBAUM 1996) JEST GROMADZENIE DANYCH DO BADAŃ PORÓWNAWCZYCH ODMIAN JĘZYKA ANGIELSKIEGO NA CAŁYM ŚWIECIE, DLATEGO TEŻ W PRACE ZAANGAŻOWANYCH JEST 15 ZESPOŁÓW, KTÓRE PRZYGOTOWUJĄ ODDZIELNE KORPUSY ELEKTRONICZNE W KRAJACH I REGIONACH, TAKICH JAK: AFRYKA WSCHODNIA, AUSTRALIA, FILIPINY, FIDŻI, HONGKONG, INDIE, IRLANDIA, JAMAJKA, KANADA, MALEZJA, NOWA ZELANDIA, RPA, SINGAPUR, SRI LANKA, STANY ZJEDNOCZONE I WIELKA BRYTANIA.
- NAJWCZEŚNIEJSZE ZGROMADZONE TEKSTY POCHODZĄ Z ROKU 1990. AUTORÓW WYPOWIEDZI PISEMNYCH LUB USTNYCH DOBRANO, TAK BY JĘZYK ANGIELSKI BYŁ DLA NICH JĘZYKIEM OJCZYSTYM;

WYBRANE KORPUSY KOMPUTEROWE

- KAŻDY KORPUS SKŁADOWY ZAWIERA OKOŁO 1 MILIONA SŁÓW (500 TEKSTÓW PO OKOŁO 2000 WYRAZÓW) W TEKSTACH NASTĘPUJĄCYCH GATUNKÓW:

– TEKSTY MÓWIONE

- TEKSTY PISANE

- CO WAŻNE, W KORPUSIE TYM PRZEWAŻAJĄ NAD TEKSTAMI PISANYMI TEKSTY MÓWIONE (60%). MOŻNA TO UZASADNIĆ TYM, ŻE RÓŻNICE MIĘDZY ODMIANAMI JĘZYKA ANGIELSKIEGO UWIDOCZNIAJĄ SIĘ SZCZEGÓLNIE W MOWIE, ZAŚ W PIŚMIE SĄ MNIEJ WYRAZISTE.

WYBRANE KORPUSY KOMPUTEROWE

THE HELSINKI CORPUS OF ENGLISH TEXTS

- KORPUS TEN (KYTÖ 1988, 1994), GROMADZONY W RAMACH PROJEKTU ROZPOCZĘTEGO W ROKU 1984, ZAWIERA WYJĄTKI Z TEKSTÓW CIĄGŁYCH POWSTAŁYCH W OKRESIE OD 750 (PIERWSZE ZACHOWANE TEKSTY) DO 1700 R. (KONIEC OKRESU WCZESNEGO NOWOCZESNEGO JĘZYKA ANGIELSKIEGO) – CZĘŚĆ DIACHRONICZNA – ORAZ TRANSKRYPCJE WSPÓŁCZESNYCH WYWIADÓW Z UŻYTKOWNIKAMI DIALEKTÓW WIEJSKICH W WIELKIEJ BRYTANII (CZĘŚĆ DIALEKTALNA). ZAWIERA OKOŁO 1,5 MILIONA SŁÓW, Z CZEGO 75% OBEJMUJE CZĘŚĆ DIACHRONICZNA, CZYLI TEKSTY HISTORYCZNE.

KORPUSY W POLSCE

DO NAJWAŻNIEJSZYCH (NAJBARDZIEJ REPREZENTATYWNYCH) NALEŻĄ:

- PELCRA
- NARODOWY KORPUS JĘZYKA POLSKIEGO
- KORPUS JĘZYKA POLSKIEGO PWN
- KORPUS IPI PAN
- I INNE ZBIORY TEKSTÓW

SZCZEGÓŁOM DOTYCZĄCYM POLSKICH KORPUSÓW POŚWIĘCONE ZOSTANIE KOLEJNE SPOTKANIE.