JĘZYKOZNAWSTWO KORPUSOWE

SPOTKANIE VIII

JOANNA SATOŁA-STAŚKOWIAK

NARZĘDZIA KOMPUTEROWE I PROCEDURY STOSOWANE W BADANIU KORPUSÓW

- KOMPUTERY WE WSPÓŁCZESNYM JĘZYKOZNAWSTWIE KORPUSOWYM STANOWIĄ PODSTAWOWE NARZĘDZIE PRACY – ZAPEWNIAJĄ OGROMNĄ SZYBKOŚĆ, POWTARZALNOŚĆ I ODTWARZALNOŚĆ OPERACJI, POZWALAJĄ WYKLUCZYĆ NIEUCHRONNY W PRZYPADKU ANALIZY MANUALNEJ ELEMENT PRZYPADKOWOŚCI W STUDIACH LINGWISTYCZNYCH I POZWALAJĄ PRACOWAĆ Z BARDZO ROZBUDOWANYMI ZBIORAMI TEKSTÓW. OFERUJĄ MOŻLIWOŚCI WYSZUKIWANIA CIĄGÓW ZNAKÓW, ICH SORTOWANIA, A TAKŻE WYKONYWANIA OBLICZEŃ STATYSTYCZNYCH, A CO ZA TYM IDZIE – PRZEJŚCIA OD JĘZYKOZNAWCZYCH BADAŃ JAKOŚCIOWYCH DO ILOŚCIOWYCH, UMOŻLIWIAJĄCYCH FORMUŁOWANIE UOGÓLNIEŃ (KENNEDY 1998: 5, POR. TAKŻE TZOUKERMAN, KLAVANS, STRZALKOWSKI 2003: 529–544).
-
-

WYSZUKIWANIE I ZASTĘPOWANIE INFORMACJI

- Do celów tych, czyli wyszukiwania i zastępowania danych, służą programy dedykowane oraz rozbudowane edytory tekstu, a także mniej zaawansowane programy przeznaczone konkretnie do wyszukiwania określonych ciągów znaków typu znajdź i zastąp. Umożliwiają one najczęściej przetwarzanie wsadowe, w przypadku którego w jednej operacji przetwarzanych jest wiele plików. W badaniach korpusowych ogromne znaczenie mają wyrażenia regularne – opisane szerzej w części 3 niniejszej pracy. Edytory odpowiednie do badań językoznawczych umożliwiają posługiwanie się wyrażeniami regularnymi o zaawansowanej składni. Przykładami edytorów, które umożliwiają korzystanie z wyrażeń regularnych, są TextPad (www.textpad.com), EditPad (www.editpadpro.com), EmEditor (www.emeditor.com), UltraEdit (www.ultraedit.com) oraz AptEdit (www.aptedit.com).

FREKWENCJA

- Sporządzanie list frekwencyjnych (list częstości wystąpień wyrazów, ich połączeń, konstrukcji gramatycznych) dla korpusów polega na przyporządkowaniu każdemu wyrazowi liczby jego wystąpień i posortowaniu wyrazów w porządku alfabetycznym lub według liczby wystąpień. Jeśli informację taką połączyć z kontekstem, w którym dany wyraz występuje, bądź funkcją, którą pełni w zdaniu, otrzymujemy wartościowe informacje o użyciu wyrazu w danej funkcji19. Podobnie, listy frekwencyjne można tworzyć na podstawie par, trójek i większej liczby współwystępujących wyrazów (n-gramów). Umożliwia to badania szeregu rodzajów stałych połączeń wyrazowych (na przykład fraz rzeczownikowych, kolokacji itd.).
- Jednym z najbardziej oczywistych zastosowań list frekwencyjnych jest dydaktyka języków obcych, w której są wykorzystywane do ustalania słownictwa podstawowego, rozumianego jako wyrazy najczęściej w języku występujące oraz przy tworzeniu słowników, ponieważ kolejne tzw. znaczenia leksykograficzne danego hasła uporządkowane są zazwyczaj zgodnie z częstością ich stosowania w języku.

LEMATYZACJA

- LEMATYZACJA (NAZYWANA NIEKIEDY HASŁOWANIEM, BIEŃ, SZAFRAN 2001: 72 LUB TEMATYZACJĄ, LEWANDOWSKA-TOMASZCZYK 2005: 68) TO SPROWADZANIE FORM FLEKSYJNYCH WYRAZU DO FORMY PODSTAWOWEJ, HASŁOWEJ, CZYLI LEKSEMU (LEMMY). W TEN SPOSÓB W JĘZYKU ANGIELSKIM ORAZ POLSKIM, NA PRZYKŁAD, RZECZOWNIKI SPROWADZANE SĄ DO MIANOWNIKA LICZBY POJEDYNCZEJ (JEŻELI FORMA TA OCZYWIŚCIE ISTNIEJE), ZAŚ CZASOWNIKI – DO BEZOKOLICZNIKA. ZMNIEJSZA SIĘ WÓWCZAS OGÓLNA LICZBA RÓŻNYCH SŁÓW W KORPUSIE, A DZIĘKI TAKIEMU PRZETWORZENIU TEKSTU MOŻNA ŁATWO ZNALEŹĆ WSZYSTKIE WYSTĄPIENIA DANEGO SŁOWA NIEZALEŻNIE OD FORMY FLEKSYJNEJ, KTÓRĄ W DANYM KONTEKŚCIE PRZYJMUJE (KLEIN, SIMMONS 1963), A W REZULTACIE – PRZEPROWADZIĆ BADANIA STATYSTYCZNE WYSTĘPOWANIA DANEGO LEKSEMU.
- LEMATYZACJĘ – WYKONYWANĄ ZA POMOCĄ TZW. ALGORYTMÓW STEMMINGU (POR. WIERZCHOŃ 2004) WYKORZYSTUJE SIĘ GŁÓWNIE W BADANIU JĘZYKÓW CHARAKTERYZUJĄCYCH SIĘ MNIEJ ZŁOŻONYM SYSTEMEM FLEKSYJNYM, W TYM W JĘZYKU ANGIELSKIM (POR. PORTER 1980, DE SCHRYVER 2003, O'GRADY ET AL. 1997)

METODY HASŁOWANIA

- Współczesne programy komputerowe służące do lematyzacji korzystają z co najmniej dwóch metod hasłowania:
- 1. Reguły zapisane w pamięci programu (program przechowuje wszystkie formy danego wyrazu i na ich podstawie określa wyraz hasłowy). Na przykład forma dopełniacza liczby pojedynczej wody zostaje sprowadzona do formy mianownikowej woda.
- 2. Jeśli dana forma w pamięci lematyzatora nie istnieje, program próbuje „odcinać" od analizowanej formy prefiksy, aby uzyskać formę znajdującą się w wykazie wyrazów (na przykład z wyrazu deinternationalisation odcięty zostanie prefiks de- i pozostanie znana forma internationalisation).
- Podstawowym problemem jest odróżnienie homografów, a więc wyrazów identycznych pod względem graficznym, jednak różniących się znaczeniem, jak w następujących przykładach:
- a) How the generalized Maxwell equations can be derived from the Einstein postulate.
- b) Hinged closure attachment for insulated beverage can container - US Patent 4872577 from Patent Storm.

ANALIZA CZĘŚCI MOWY

- ADNOTACJA W KORPUSIE CZĘŚCI MOWY (ANG. PART-OF-SPEECH ANNOTATION), OKREŚLANA TAKŻE JAKO ADNOTACJA GRAMATYCZNA LUB MORFOSYNTAKTYCZNA, JEST PROCESEM BARDZIEJ ZŁOŻONYM OD LEMATYZACJI I CZĘSTO PROWADZONYM RÓWNOLEGLE, TAKŻE Z TEGO WZGLĘDU, ŻE INFORMACJA O CZĘŚCI MOWY POZWALA Z WIĘKSZĄ PRECYZJĄ OKREŚLIĆ FORMĘ WYRAZU HASŁOWEGO, NA PRZYKŁAD ROZRÓŻNIĆ HOMOGRAFY (CHOĆ TYLKO, JEŚLI RÓŻNIĄ SIĘ CZĘŚCIĄ MOWY; RÓŻNICE SEMANTYCZNE POZOSTAJĄ POZA ZASIĘGIEM TEJ METODY).
- PROGRAMY KOMPUTEROWE DO AUTOMATYCZNEJ ANALIZY CZĘŚCI MOWY TO ANALIZATORY MORFOLOGICZNE, ZAŚ ZESTAW SYMBOLI OPISUJĄCYCH POSZCZEGÓLNE KATEGORIE ZWANY JEST Z JĘZYKA ANGIELSKIEGO TAGSETEM.

TAGSET

- Tagset powinien w sposób kompletny (ze względu na przyjętą gramatykę morfologiczną) opisywać wszystkie kategorie w danym języku w sposób możliwie precyzyjny, tak by dla każdego wyrazu istniała odpowiadająca mu kategoria, nawet jeśli w danym przypadku analizator dokonałby błędnego przypisania. Mimo że pierwsze analizatory komputerowe korzystały z niezłożonej listy kategorii, a ponadto każdy program opierał się na innej liście (Stolz 1965, Klein, Simmons 1963), co uniemożliwiało porównywanie wyników, tagsety współczesne charakteryzują się dekompozycyjnością i hierarchicznością (Lewandowska-Tomaszczyk 2005: 78). Dekompozycyjność tagsetów polega na tym, że każdy znak lub ich ciąg ma odrębne znaczenie i w różnych kombinacjach może wchodzić w skład większej liczby indeksów. Z kolei hierarchiczność powoduje, że sekwencja znaków indeksu składa się ze znaków od bardziej ogólnych do szczegółowych. Dzięki temu konstrukcja indeksów jest logiczna, a liczba różnych ich składników powinna być mniejsza od całkowitej liczby indeksów, co ułatwia posługiwanie się nimi.

TOKENIZACJA

- Tokenizacja to podział tekstu wejściowego na jednostki, które zostaną poddane analizie. W języku polskim za granice wyrazów można przyjąć spację lub znak interpunkcyjny (na przykład przecinek, kropka, cudzysłów zamykający, średnik, dwukropek, wykrzyknik, znak zapytania), jednak język angielski, na przykład, juŝ na tym etapie analizy powoduje pewne trudności:
- Jack's at home (≡Jack is at home): Jack's to dwa słowa.
- Jack's home is awesome: Jack's to jedno słowo (dopełniacz saksoński).
- Trudność ponadto sprawiają w języku angielskim wyrazy pisane z łącznikiem (np. B-52, self-evaluation, twenty-two), które uznaje się za pojedynczą jednostkę, i frazy typu acid-containing, które stanowią dwie jednostki.

ANALIZA

- Na etapie analizy wykorzystuje się dwie metody analogiczne do stosowanych przy lematyzacji, to znaczy porównywanie danych wejściowych z listą słów i ich form (uzyskaną w wyniku analizy innych korpusów lub na podstawie słownika) oraz analizę morfologiczną (ang. affix stripping) dokonywaną na podstawie zbioru reguł fleksyjnych danego języka. Na tym etapie analizator w wielu przypadkach przypisuje wyrazowi więcej niŝ jedną moŝliwą kategorię (np. w języku polskim kara jako rzeczownik lub przymiotnik, zaś w języku angielskim water jako rzeczownik lub czasownik), dlatego niezbędny jest etap kolejny, czyli dezambiguacja.

DEZAMBIGUACJA

- Dezambiguacja
- Na tym etapie dane wejściowe to wszystkie wyrazy, którym przypisano więcej niż jedną kategorię, zatem konieczny jest wybór jednego, poprawnego indeksu. Ponieważ na podstawie samego wyrazu i jego formy nie jest możliwe przypisanie jednoznaczne, następuje analiza kontekstu, czyli otoczenia badanego wyrazu.

PARSING

- Parsing to pełna analiza syntaktyczna tekstu – a w ogólniejszym ujęciu każdej liniowej sekwencji elementów, w której wzajemna kolejność poszczególnych elementów podlega pewnym ograniczeniom związanym z daną gramatyką, czyli pewnym zbiorem reguł (Grune, Jacobs 1990: 13) – prowadząca do przypisania poszczególnym wyrazom pełnej adnotacji zawierającej informację już nie o części mowy, ale części zdania. Przypisanie to przeprowadza się zazwyczaj po analizie morfologicznej. Z racji typowej postaci analizy zdania korpusy poddane analizie syntaktycznej określa się jako „banki drzew" (częściej stosuje się określenie angielskie treebanks). Aby ułatwić zapis, drzewa opisujące poszczególne zdania nie mają postaci graficznej, lecz tekstową. Na przykład w notacji stosowanej w British National Corpus adnotowane zdanie „Claudia sat on a stool" ma następującą postać:

PARSING

- [S[NP Claudia_NP1 NP] [VP sat_VVD [PP on_II [NP a_AT1 stool_NN1 NP] PP] VP] S]20
- (McEnery, Wilson, 1996: 44)
- Ponieważ nawet dla specjalisty analiza składniowa w pewnych przypadkach nie jest zadaniem trywialnym, parsing automatyczny jest jednym z najtrudniejszych problemów komputerowej analizy tekstu, wskutek czego skuteczność programów do analizy syntaktycznej (parserów) jest niższa niż analizatorów morfologicznych. Dlatego też często parsing komputerowy wspomaga się przez adnotowanie ręczne, którego ograniczeniem jest z kolei niemożność uzyskania całkowitej powtarzalności adnotacji i znacznie mniejsza wydajność pracy.

- Parsing jest wykorzystywany (Grune, Jacobs 1990: 11) nie tylko w językoznawstwie (analiza tekstu, analiza korpusowa, tłumaczenie maszynowe), ale także w redagowaniu i konwersji dokumentów, informatyce (np. opracowywanie kompilatorów, interfejsy baz danych, sztuczna inteligencja), a nawet naukach biologicznych (składanie wzorów chemicznych i identyfikacja chromosomów).

KONKORDANCJA

- Konkordancja to lista słów występujących w danym tekście (określanych niekiedy jako słowa kluczowe, ang. keywords) w postaci cytatów obejmujących słowa poprzedzające dane słowo i po nim następujące (liczbę słów otaczających można zmieniać zależnie od potrzeb). W ten sposób uzyskuje się przejrzysty wykaz wszystkich użyć danego wyrazu w całym tekście lub w zbiorze tekstów (a zatem także ich znaczeń), a także częstotliwość użycia wyrazu. Otrzymaną listę można poddać sortowaniu alfabetycznemu w dowolnej konfiguracji, a dzięki temu – badać kolokacje, znaczenia słów oraz przykłady użycia słów bądź fraz21.
- Mimo że obecnie konkordancje są automatycznie generowane przez programy komputerowe (dostępne na przykład wraz z korpusem PELCRA), pojęcie konkordancji i pierwsze prace nad tym zagadnieniem sięgają wieku XVIII, kiedy to Alexander Cruden w 1737 r. wydał konkordancję Biblii Króla Jakuba.
- Przykładem współczesnego programu do wyszukiwania konkordancji są narzędzia dostępne w korpusie Bank of English wydawnictwa Collins.

KONKORDANCJA

- Spośród wielu historycznych i współczesnych formatów zapisu konkordancji obecnie najczęściej wykorzystuje się format KWIC (ang. Key Word in Context), w którym po numerze linii, w której występuje szukany wyraz, podawany jest kontekst lewostronny (długość ustawiana przez użytkownika), szukany wyraz oraz kontekst prawostronny (długość ustawiana przez użytkownika).