KORPUSY JĘZYKOWE

SPOTKANIE II

JOANNA SATOŁA-STAŚKOWIAK

CO TO JEST KORPUS JĘZYKOWY?

- NA TEN TEMAT WYPOWIADA SIĘ WSPÓŁCZEŚNIE WIELU PROPAGATORÓW NAJNOWSZYCH TECHNOLOGII JĘZYKOZNAWCZYCH, M.IN. T. PIOTROWSKI, KTÓRY DEFINIUJE KORPUS JAKO: „ZBIÓR TEKSTÓW ZAPISANYCH W POSTACI CYFROWEJ I STANOWIĄCYCH REPREZENTATYWNĄ PRÓBKĘ DANEGO JĘZYKA. KORPUS RÓŻNI SIĘ OD DOWOLNEGO ZBIORU TEKSTÓW TYM, ŻE STANOWI PEWNĄ PRZEMYŚLANĄ CAŁOŚĆ. CECHĄ WYRÓŻNIAJĄCĄ KORPUSÓW KOMPUTEROWYCH JEST TEŻ ICH ROZMIAR" [PIOTROWSKI 2003: 146].

CO TO JEST KORPUS JĘZYKOWY?

- Znacznie szersze ujęcie definicji korpusu przedstawił wcześniej Kennedy (1998: 1), według którego „korpus jest zbiorem tekstów pisanych lub transkrypcji wypowiedzi mówionych; na jego podstawie prowadzi się analizy językoznawcze i dokonuje opisu języka". I kontynuuje: „wprowadzenie komputerów do badań korpusowych nie zmieniło istoty tych badań, mimo że wielu badaczy tak sądzi, a w żadnym razie komputery nie wyznaczają początku badań korpusowych, mimo że znacznie je przyspieszyły i ułatwiły". Należy ponadto pamiętać, że mimo ogromnego postępu technologicznego w wielu aspektach badań korpusowych ingerencja człowieka jest nieodzowna (na przykład w weryfikacji analizy morfologicznej i składniowej).

CO TO JEST KORPUS JĘZYKOWY?

- Należy w tym miejscu odróżnić korpus rozumiany współcześnie od zbioru tekstów, określanego niekiedy mianem archiwum (Kennedy 1998). Drugie pojęcie ma szerszy zakres, ponieważ – w przeciwieństwie do korpusu – nie narzuca ograniczeń w doborze tekstów, ich proporcjach i strukturze, a często jego głównym zadaniem i powodem gromadzenia tekstów są nie badania naukowe, a dostęp do tekstów (czytanie). Korpus zaś jest zbiorem tekstów charakteryzującym się systematycznością, zgromadzonym ściśle według założonego planu (patrz rozdział 1, punkt 2), nie jest „zbiorem tekstów zgromadzonych w sposób losowy" (Aston, Burnard 1998: 21). Leech (1991: 11) stwierdza, że „różnica między archiwum a korpusem polega na tym, że korpus opracowuje się z myślą o reprezentatywności", rozumianej jako celowy, świadomy i zaplanowany dobór tekstów w zbiorze.

CO TO JEST KORPUS JĘZYKOWY?

- Przez korpus rozumiemy zbiór tekstów jednego języka, albo zbiór tekstów w dwóch lub wielu językach (nazywamy go wtedy korpusem równoległym), w którym każdy tekst ma swój odpowiednik w co najmniej jednym innym języku. Teksty w takim korpusie mogą być zestawione (ang. aligned), np. na poziomie akapitu lub zdania.

- Przykładem jednego z bardziej znanych w Polsce korpusów jest Narodowy Korpus Języka Polskiego (http://www.nkjp.pl/). Na jego podstawie powstał Słownik Języka Polskiego PWN.

CO TO JEST KORPUS JĘZYKOWY?

- NIEKTÓRE KORPUSY BYWAJĄ OKREŚLANE MIANEM ZRÓWNOWAŻONYCH - OZNACZA TO, ŻE PRÓBKI TEKSTU DO KORPUSU WYBRANE ZOSTAŁY WEDŁUG SPECJALNEGO KLUCZA, TAK BY ZAPEWNIĆ POŻĄDANE PROPORCJE POMIĘDZY RÓŻNYMI STYLAMI CZY OKRESAMI POWSTAWANIA TEKSTÓW. PRZYKŁADEM KORPUSU ZRÓWNOWAŻONEGO MOŻE BYĆ KORPUS SŁOWNIKA FREKWENCYJNEGO POLSZCZYZNY WSPÓŁCZESNEJ (OBECNIE ZNANY TAKŻE JAKO KORPUS POLSZCZYZNY LAT SZEŚĆDZIESIĄTYCH XX WIEKU), SKŁADAJĄCY SIĘ W RÓWNYCH CZĘŚCIACH (PO 10000 PRÓBEK) Z TEKSTÓW POPULARNONAUKOWYCH, DROBNYCH WIADOMOŚCI PRASOWYCH, PUBLICYSTYKI, PROZY ARTYSTYCZNEJ I DRAMATU ARTYSTYCZNEGO.

ZASTOSOWANIE KORPUSÓW

- KENNEDY (1998: 11) WYMIENIA SZEREG ZASTOSOWAŃ ZBIORÓW TEKSTÓW: OPRACOWYWANIE SŁOWNIKÓW, LIST SŁÓW I GRAMATYK DESKRYPTYWNYCH, BADANIA SYNCHRONICZNE I DIACHRONICZNE ODMIAN JĘZYKA, ZAGADNIENIA STYLU, NAUCZANIE JĘZYKA OJCZYSTEGO I OBCEGO, BADANIA STATYSTYCZNE ROZKŁADU FONEMÓW, BADANIA DOTYCZĄCE INTERPUNKCJI, FLEKSJI, DERYWACJI, ANALIZA KOLOKACJI I INNYCH ELEMENTÓW JĘZYKA.
- KORPUSY JĘZYKOWE ZNALAZŁY SZEROKIE ZASTOSOWANIE WE WSPÓŁCZESNEJ LEKSYKOGRAFII. SĄ TEŻ WYKORZYSTYWANE JAKO ZBIORY DANYCH UCZĄCYCH I TESTOWYCH W METODACH UCZENIA MASZYNOWEGO STOSOWANYCH W PRZETWARZANIU JĘZYKÓW NATURALNYCH.
- TO ZBIORY TEKSTÓW SŁUŻĄCY BADANIOM LINGWISTYCZNYM, NP. OKREŚLANIU CZĘSTOŚCI WYSTĘPOWANIA FORM WYRAZOWYCH, KONSTRUKCJI SKŁADNIOWYCH, KONTEKSTÓW W JAKICH POJAWIAJĄ SIĘ DANE WYRAZY.