JĘZYKOZNAWSTWO KORPUSOWE

SPOTKANIE VII

JOANNA SATOŁA-STAŚKOWIAK

KORPUSY JĘZYKOWE W POLSCE

- JEDNYM Z PIERWSZYCH DONIOSŁYCH WYDARZEŃ W POLSKIM JĘZYKOZNAWSTWIE KORPUSOWYM BYŁO SPORZĄDZENIE LIST FREKWENCYJNYCH JĘZYKA POLSKIEGO (KURCZ ET AL. 1974–1977), A NA ICH PODSTAWIE – W LATACH DZIEWIĘĆDZIESIĄTYCH UBIEGŁEGO WIEKU – SŁOWNIKA FREKWENCYJNEGO POLSZCZYZNY WSPÓŁCZESNEJ (KURCZ ET AL. 1990).

PELCRA

- Projekt ten jest wynikiem współpracy Katedry Języka Angielskiego Uniwersytetu Łódzkiego (obecnie – Katedry Języka Angielskiego i Językoznawstwa Stosowanego) i Departamentu Językoznawstwa i Współczesnego Języka Angielskiego Uniwersytetu w Lancaster. PELCRA (Polish and English Language Corpora for Research and Application) miał następujące zadania (Lewandowska-Tomaszczyk 2005: 19):

1. gromadzenie danych języka polskiego, danych o języku angielskim używanym przez jego polskich użytkowników a także tekstów oryginałów i ich przekładów w parze językowej polski-angielski.
2. zapisanie zgromadzonych danych w postaci elektronicznej (wykorzystano strukturę analogiczną do British National Corpus)
3. udostępnianie aplikacji służących do obróbki zawartych w korpusie danych (szereg narzędzi do badania konkordancji, fleksji, częstości słów i kolokacji) (http://pelcra.ia.uni.lodz.pl/intro_pl.php).

PELCRA

- W skład korpusów językowych opracowanych w ramach projektu wchodzą:

– Polski Korpus Narodowy (Polish National Corpus) – korpus referencyjny języka polskiego zawierający ponad 130 milionów wyrazów, z czego udostępniona do powszechnego użytku jest jego część zbalansowana licząca 93 milionów segmentów słów.

– Polski Korpus Uczniowski Języka Angielskiego (Polish Learner English Corpus) liczący obecnie około 500 000 słów, w którym zawarto dane zgromadzone od uczących się na różnych poziomach zaawansowania. Korpus ten posłuży do badań kontrastywnych (np. badania określoności, części mowy, stałych związków wyrazowych), a także analizy błędów popełnianych przez uczących się.

–

PELCRA

– Polski Multimedialny Korpus Konwersacyjny (Polish Spoken Conversational Multimedia Corpus, 500 000 słów, docelowo – 1 milion). Część korpusu referencyjnego obejmująca dane mówione. Rejestrowano wypowiedzi spontaniczne, przy czym rozmówcy nie byli informowani o nagrywaniu. Korpus jest adnotowany – zawiera informacje o płci, wieku i wykształceniu rozmówców oraz o podstawowych cechach prozodycznych. Dane dostępne są także w postaci plików dźwiękowych MP3, co umożliwia bezpośrednią analizę charakterystyki prozodycznej.

– Angielsko-polskie i polsko-angielskie korpusy paralelne (równoległe) i porównywalne. Korpusy zawierające głównie teksty oryginalne i ich tłumaczenia (przede wszystkim w kierunku z języka polskiego na angielski) czasopism i książek, służące do badań kontrastywnych i translatologicznych.

Obecnie projekt PELCRA jest realizowany w ramach Narodowego Korpusu Języka Polskiego (NKJP).

NARODOWY KORPUS JĘZYKA POLSKIEGO

- Korpus ten jest tworzony we współpracy Instytutu Podstaw Informatyki PAN (koordynator), Instytutu Języka Polskiego PAN, Wydawnictwa Naukowego PWN oraz Zakładu Językoznawstwa Komputerowego i Korpusowego Uniwersytetu Łódzkiego.
- Wedle założeń (Przepiórkowski et al. 2009) korpus ten ma zawierać 1 miliard wyrazów, z czego subkorpus liczący co najmniej 300 milionów wyrazów ma być starannie zrównoważony. Na podstawie korpusu konwersacyjnego PELCRA zostanie opracowana część (30 milionów wyrazów) zawierająca wypowiedzi mówione (przemówienia publiczne, protokoły obrad parlamentarnych, debaty telewizyjne i inne, w tym podzbiór z wypowiedziami naturalnymi użytkowników języka – 3 miliony wyrazów).
- Cały korpus będzie anotowany pod względem lingwistycznym, strukturalnym i bibliograficznym, przy czym ze względu na wielkość korpusu anotacja manualna będzie obejmować subkorpus złożony z 1 miliona wyrazów.

KORPUS JĘZYKA POLSKIEGO PWN

- Korpus opracowany przez Wydawnictwo Naukowe PWN, dostępny częściowo w Internecie.
- Wersja sieciowa, dostępna bezpłatnie, jest zrównoważona tematycznie i gatunkowo. Obejmuje 661 próbek tekstu o objętości od 1 do 1,5 arkusza wydawniczego w przypadku książek i czasopism oraz 0,5 arkusza w przypadku poezji i gazet codziennych. Próbki pobierano z 75 książek beletrystycznych, 115 niebeletrystycznych i 154 numerów 72 tytułów prasowych. Ponadto w korpusie umieszczono 69 plików z transkrypcjami rozmów i 85 plików z ulotkami reklamowymi i innymi tekstami użytkowymi. Łącznie korpus ten obejmuje ponad 3,7 miliona wyrazów.
- Wersja pełna z kolei obejmuje 2070 próbek tekstów o rozmiarach od 1 do 6 arkuszy wydawniczych, pobieranych z 195 książek beletrystycznych i 191 niebeletrystycznych oraz 977 numerów 185 tytułów prasowych. Ponadto 84 pliki z transkrypcjami rozmów, 272 pliki z ulotkami reklamowymi oraz 207 plików z tekstami internetowymi.

KORPUS JĘZYKA POLSKIEGO PWN

- KORPUSY MAJĄ CHARAKTER DIACHRONICZNY, PONIEWAŻ UMIESZCZONO W NICH NIE TYLKO TEKSTY WSPÓŁCZESNE, ALE TAKŻE DAWNIEJSZE (4,5% TEKSTÓW Z LAT 1920–1945 ORAZ 10% TEKSTÓW Z LAT 1946–1969).
- PLIKI ZNAJDUJĄCE SIĘ W OBU KORPUSACH SĄ INDEKSOWANE. TAGI OBEJMUJĄ INFORMACJE O STRUKTURZE TEKSTU, WYRAZACH I KONSTRUKCJACH NIETYPOWYCH BĄDŹ BŁĘDNYCH ORAZ DANE O AUTORACH LUB UCZESTNIKACH ROZMÓW.
- INFORMACJE O KORPUSIE SĄ DOSTĘPNE NA STRONIE HTTP://KORPUS.PWN.PL/.

KORPUS IPI PAN

- KORPUS TEN, LICZĄCY 250 MLN WYRAZÓW, ZOSTAŁ UTWORZONY PRZEZ ZESPÓŁ INŻYNIERII LINGWISTYCZNEJ W INSTYTUCIE PODSTAW INFORMATYKI PAN (IPI PAN) (PRZEPIÓRKOWSKI 2004).
- OBECNIE DOSTĘPNE JEST 2. WYDANIE KORPUSU Z MARCA 2006 R.: WERSJA PEŁNA ORAZ PRÓBKA, ZAWIERAJĄCA PONAD 30 MLN WYRAZÓW, KTÓREJ SKŁAD JEST NASTĘPUJĄCY: PROZA WSPÓŁCZESNA (PONAD 10%), PROZA DAWNA (PRAWIE 10%), TEKSTY KSIĄŻKOWE NIEBELETRYSTYCZNE (10%), PRASA (50%), STENOGRAMY PARLAMENTARNE (15%), USTAWY (5%).
- PEŁNE INFORMACJE ZNAJDUJĄ SIĘ NA STRONIE INTERNETOWEJ WWW.KORPUS.PL.

ZBIORY TEKSTÓW

- Zbiory omówione powyżej to typowe korpusy, a więc kolekcje tekstów gromadzone przez językoznawców do badań, podporządkowane z góry ustalonym regułom. Wartościowym, także naukowo − chociaż niewątpliwie niereprezentatywnym i nieoddającym języka jako całości – rodzajem materiału, są zbiory tekstów, które coraz częściej dostępne są, za opłatą (archiwum Gazety Wyborczej, Rzeczpospolitej, Science) lub bez (archiwum Die Zeit, Projekt Gutenberg) – w sieci WWW w postaci elektronicznej.
- Problemem może być w takim wypadku dostęp do archiwum jako całości, a więc pobranie pełnych tekstów, najdogodniej w formacie .html lub .txt. Część bowiem plików – na przykład artykułów prasowych – dostępna jest wyłącznie w formacie .pdf, który najczęściej (w przypadku plików tworzonych przez oprogramowanie OCR) nie nadaje się do badań bez wcześniejszego przekształcenia w format możliwy do odczytania, natomiast to przekształcenie wiąże się z koniecznością wykonania szeregu czynności manualnych (np. problem interpretacji znaków przeniesienia).

ZBIORY TEKSTÓW – PRZYKŁADY:

– ARCHIWUM TYGODNIKA TIME – LICZĄCE PONAD 100 MILIONÓW WYRAZÓW ARCHIWUM OBEJMUJĄCE TEKSTY OD ROKU 1923 (HTTP://CORPUS.BYU.EDU/TIME/),

– PROJEKT GUTENBERG – ARCHIWUM GROMADZI TEKSTY KSIĄŻEK ZNAJDUJĄCYCH SIĘ W DOMENIE PUBLICZNEJ, A ZATEM TAKICH, DO KTÓRYCH WYGASŁY PRAWA AUTORSKIE (OBECNIE W USA WYGAŚNIĘCIE PRAW NASTĘPUJE 50 LAT PO ŚMIERCI AUTORA). OBEJMUJE LITERATURĘ POPULARNĄ I PIĘKNĄ ORAZ ŹRÓDŁA O CHARAKTERZE LEKSYKOGRAFICZNYM CZY ENCYKLOPEDYCZNYM (SŁOWNIKI, ENCYKLOPEDIE, TEZAURUSY) GŁÓWNIE W RAMACH KULTURY ZACHODNIEJ, W JĘZYKU ANGIELSKIM, ALE TAKŻE FRANCUSKIM, NIEMIECKIM, FIŃSKIM I INNYCH. JĘZYK POLSKI TAKŻE JEST REPREZENTOWANY, NIESTETY JEDNAK SZCZĄTKOWO (HTTP://WWW.GUTENBERG.ORG/WIKI/MAIN_PAGE); DOSTĘPNE SĄ NA PRZYKŁAD NASTĘPUJĄCE TEKSTY: PAN TADEUSZ ORAZ SONETY ADAMA MICKIEWICZA, SKLEPY CYNAMONOWE BRUNONA SCHULZA I INNE POZYCJE; WYSZUKIWARKA W 2006 R. PODAWAŁA 25 POZYCJI, ZAŚ 12 MAJA 2011 R. DOSTĘPNYCH BYŁO 29 POZYCJI, CO OZNACZA, ŻE PRZYROST NIE JEST ZNACZNY, Z KOLEI W PRZYPADKU JĘZYKA ANGIELSKIEGO BYŁO TO 30178 POZYCJI,

ZBIORY TEKSTÓW – PRZYKŁADY:

– Oxford Text Archive – kilkaset tysięcy tekstów naukowych (w tym także korpusów językowych) w wielu językach w postaci elektronicznej (Burnard 1988, Edwards 1993) (http://ota.ahds.ac.uk/),

– European Corpus Inititative – projekt rozpoczęty w 1992. Zawiera teksty przede wszystkim w językach europejskich, w tym dużą liczbę wydań gazety Frankfurter Rundschau. Mimo obecności wielu języków Europy Środkowo-Wschodniej, tekstów polskich w zbiorze nie ma,

– archiwum Gazety Wyborczej – największe z ogólnodostępnych archiwum polskich tekstów prasowych, zawierające ponad 3 miliony tekstów: z wydania głównego począwszy od 1992 roku, zaś z wydań lokalnych – od roku 1999 (http://szukaj.gazetawyborcza.pl/archiwum/0,0.html),

ZBIORY TEKSTÓW – PRZYKŁADY:

– ARCHIWUM TYGODNIKA POLITYKA – ZAWIERA TEKSTY OD ROKU 1998 DO CHWILI OBECNEJ. UMOŻLIWIA WYSZUKIWANIE ZAAWANSOWANE (SZUKANE SŁOWO, AUTOR, SŁOWA W TYTULE, ZAKRES DAT WYDANIA, RUBRYKA, DZIAŁ),

– ARCHIWUM DZIENNIKA RZECZPOSPOLITA – ZAWIERA TEKSTY OD ROKU 1993 DO CHWILI OBECNEJ, W TYM DOKUMENTY Z SERWISU PRAWNEGO I EKONOMICZNEGO ORAZ Z DODATKÓW.