Rozdział 4

Narzędzia wspomagające tłumaczenie tekstów

W niniejszym rozdziale porównane zostały podstawowe właściwości wybranych programów wspomagających tłumaczenie różnego rodzaju tekstów. Na końcu rozdziału opisano rodzaje dostępnych słowników elektronicznych.

4.1. Swobodne oprogramowanie

Na rynku dostępnych jest szereg daramowych programów wspomagających tłumaczy w ich codziennej pracy. Jak pisałem w pierwszym rozdziale, programy pełnią różne funkcje i są użyteczne na różnych etapach procesu tłumaczenia.

Okazuje się, że cały proces tłumaczenia przedstawiony w rozdziale 3.1 "Tłumaczenie tekstu przy użyciu programu CAT" można zrealizować przy pomocy darmowych narzędzi:

4.1.1. Podział tekstu na segmenty

Jednym z programów, umożliwiających podział tekstu na segmenty, tłumaczenie wstępne, weryfikację, ręczne tłumaczenie pozostałych segmentów i scalenie ich w całość, jest program OmegaT. Program ten obsługuje następujące formaty dokumentów:

- HTML, XHTML
- OpenOffice.org / StarOffice

Bardziej szczegółowy opis programu znajduje się w pracy [GNI01].

Tłumaczone teksty, zwłaszcza informatyczne, przekształcane są na pliki *po*, które obsługiwane są przez kilka popularnych programów CAT. W przypadku dokumentacji Fedora Core, pliki te generowane są przy pomocy dostarczonego skryptu, uruchamianego z katalogu, w którym znajduje się dokumentacja.

Istnieje ogólnodostępny pakiet narzędzi umożliwiających generowanie plików *po* na podstawie dokumentów w różnych formatach, a następnie scalanie przetłumaczonego tekstu na podstawie oryginalnego dokumentu i tłumaczenia w pliku *po*. Pakiet nazywa się *po4a* i jest dostępny na stronie: `http://po4a.alioth.debian.org/`.

Podział tektu na segmenty w przypadku pakietu *po4a* polega na stworzeniu pliku *po*. W przypadku tłumaczenia pierwszej wersji dokumentu, należy użyć następujego polecenia:

```
po4a-gettextize -f <format> -m <plik_do_tłumaczenia> -p <plik_po>
```

	poEdit	KBabel	gtranslator
Obsługa formatu PO	Tak	Tak	Tak
Obsługa formatu XLIFF	Nie	Tak	Nie
Funcke programów			
Obsługa TMX	Nie	Tak	Nie
Podświetlanie składni	Nie	Tak	Tak
Obsługa UTF-8	Tak	Tak	Tak
Sprawdzanie pisowni	Nie	Tak	Tak
Integracja ze słownikiem	Nie	Tak	Nie
Automatyczne tłumaczenie	Tak	Tak	Tak
Ocena interfejsu użytkownika	4	10	6

Tabela 4.1: Porównanie programów

gdzie:

- format to jeden z poniższych formatów plików, obsługiwanych przez pakiet *po4a*
  - nroff - format stron podręcznika ekranowego
  - pod - format dokumentacji perla
  - sgml - bardzo popularny format tworzenia dokumentacji;obecnie wspierane jest DTD *debiandoc-sgml*
  - xml - również popularny format tworzenia dokumentacji; obecnie wspierane jest DTD *docbook*
  - TeX/LaTeX - główny format dokumentacji używany w publikacjach pisanych przez ludzi związanych z wolnym oprogramowaniem
  - texinfo - format dokumentacji GNU
- plik_do_tłumaczenia to nazwa pliku, który będzie analizowany
- plik_po nazwa pliku *po*, który ma zostać wygenerowany

Jeśli tłumaczona ma być kolejna, zmieniona wersja dokumentu, można użyć polecenia:

```
po4a-updatepo -f <format> -m <plik_do_tlumaczenia> -p <plik_po>
```

gdzie: *plik_po*, to plik *po*, który ma zostać zaktualizowany, a pozostałe parametry, tak jak w przypadku *po4a-gettextize*

Tak przygotowane pliki należy przetłumaczyć, najlepiej wykorzystując dostępne programy CAT.

4.1.2. Tłumaczenie tekstu

Istnieje kilka programów wspomagających tłumaczenie plików *po*. Wcześniej opisane zostały programy KBabel, gtranslator. Dość popularny jest jeszcze program poedit.

Pliki *po* nie są obsługiwane przez programy pisane w języku Java. Ten język programowania ma swój mechanizm przechowywania komunikatów, który został opisany w rozdziale 2 - "Internacjonalizacja". Jak opisano w tym rozdziale, edycja tych plików w edytorach tekstu jest uciążliwa, a narzędziem ułatwiającym to zadanie jest program *propedit* dostępny na stronie `http://propedit.sourceforge.jp/index_en.html`.

4.1.3. Scalenie dokumentu i ostateczna weryfikacja

Na początku pracy z dokumentem, jego treść została oddzielona od formatowania przy pomocy programu po4a-gettextize. Teraz, po zakończonym procesie tłumaczenia, należy sformatować przetłumaczony tekst tak, aby wyglądał jak oryginał. Do tego celu służy program po4a-translate, który w miejsce oryginalnego tekstu w dokumencie źródłowym wstawia tłumaczenia z pliku *po*:

```
po4a-translate -f <format> -m <plik_do_tlumaczenia> \
           -p <plik_po> -l <plik_wyjściowy>
```

gdzie: *plik_po*, to plik *po* z przetłumaczonym tekstem, *plik_wyjściowy* to nazwa dokumentu generowanego przez program, a pozostałe parametry, tak jak w przypadku *po4a-gettextize*.

Tak przygotowany dokument, po weryfikacji, gotowy jest do opublikowania.

4.2. Słowniki

W poprzednim rozdziale omówione zostały sposoby przygotowywania oprogramowania do obsługi wielu języków oraz metody i narzędzia wspomagające automatyzację tłumaczenia tekstów.

Ten rozdział poświęcony został części komputerowego wspomagania tłumaczenia, umożliwiającej tłumaczowi szybkie i w miarę możliwości automatyczne dotarcie do tłumaczeń poszczególnych terminów. Z pomocą przychodzą tutaj słowniki, glosariusze, bazy terminologiczne oraz takie usługi dostępne w Internecie, jak grupy dyskusyjne i portale informacyjne.

Coraz częściej tłumacz sięga po elektroniczne wersje słowników, skracając czas potrzebny do odnalezienia tłumaczenia szukanego terminu. Internet stał się potężną bazą, umożliwiającą jednoczesne przeszukiwanie wielu słowników. Możliwa stała się również integracja dostępnych w Internecie zasobów słownikowych z oprogramowaniem CAT, co zwalnia użytkownika z potrzeby wpisywania szukanych słów do formularza wyszukiwarki.

4.2.1. Oprogramowanie i źródła dostępne w Internecie

Jeszcze kilka lat temu najpopularniejsze elektroniczne słowniki dystrybuowane były w postaci programów na płytach CD-ROM. Takie programy były elektronicznymi wersjami wydań papierowych i dzięki interfejsowi użytkownika umożliwiały łatwe wyszukiwanie terminów. Popularnym słownikiem był swego czasu "Słownik języka polskiego PWN". Przykłady innych słowników wydanych na płycie CD-ROM, to "Multimedialny słownik polsko-niemiecki" firmy LexLand s.c., czy "słowniki angielsko-polskie polsko-angielskie" firmy Leksykonia.

Dziś bardzo dużo różnego rodzaju słowników dostępnych jest przez Internet. To medium ma jedną, bardzo ważną przewagę nad oprogramowaniem instalowanym na komputerze. Jest nią natychmiastowy dostęp użytkowników do najbardziej aktualnej wersji bazy terminologicznej. Umożliwa to zarówno wprowadzanie do słownika nowych terminów, jak i umożliwia natychmiastową rekcję w przypadku wykrycia błędu w istniejących danych. Kilka słowników dostępnych przez Internet:

- Słownik wyrazów obcych i zwrotów obcojęzycznych Władysława Kopalińskiego (`http://www.slownik-online.pl/index.php`)
- Słownik języka polskiego PWN (`http://sjp.pwn.pl/`)

- Darmowy Słownik LING (www.ling.pl), zawierający słowniki angielski, niemiecki, francuski, włoski, hiszpański, rosyjski i polski słownik ortograficzny
- Słownik angielski (`http://www.dict.pl/`)
- Słownik niemiecki (`http://www.dep.pl/`)
- Słownik języka angielskiego (`http://dictionary.reference.com/`)
- Encyklopedia Matematyki (`http://mathworld.wolfram.com/`)

Omawiając słowniki dostępne w Internecie, nie sposób nie wspomnieć o rewolucyjnym pomyśle stworzenia „wolnej encyklopedii". Wikipedia (`http://www.wikipedia.org/`), bo tak nazywa się to przedsięwzięcie, tworzona jest przez wszystkich internautów, chcących dzielić się swoją wiedzą z innymi. Powstała ona w roku 2000 jako Nupedia, natomiast jej odsłona oparta o koncepcję wiki została uruchomiona 10 stycznia 2001. Dziś Wikipedia ma prawie 1 300 000 haseł. Polska wersja encyklopedii powstała ledwie dziewięć miesięcy później - 2 września 2001 roku i ma już ponad 270 000 haseł.

Sukces Wikipedii spowodował powstanie Wikisłownika (`http://www.wiktionary.org/`) - słownika wielojęzykowego z definicjami, etymologią, ortografią, formami fleksyjnymi, itp. dostępnego (podobnie, jak wikipedia) na zasadach Licencji Wolnej Dokumentacji GNU. Od czasu powstania polskiego wydania Wikisłownika 22 marca 2004, znajduje się tam już ponad 45 000 haseł.

4.2.2. Protokół DICT

Rosnąca liczba słowników dostępnych w Internecie umożliwia odnalezienie tłumaczeń coraz większej liczby terminów. Wraz z rosnącą liczbą słowników pogłębia się jednak problem odnalezienia tego, który będzie zawierał definicję lub tłumaczenie poszukiwanego słowa. Istnieje coraz większa potrzeba udostępniania pojedynczego interfejsu użytkownika udostępniającego wiele słowników równocześnie. Istnienie takiego interfejsu umożliwia również łatwiejsze dotarcie do odbiorcy, wystarczy bowiem przygotować odpowiednią bazę, nie martfiąc się o interfejs dla użytkownika końcowego.

Z pomocą przyszedł w 1997 roku DICT[RFC01] (The Dictionary Server Protocol), definiujący protokół pytań i odpowiedzi opartych na transmisji TCP, który umożliwia aplikacjom klienckim dostęp do definicji haseł z różnych słowników.

Protokół DICT oparty jest na stałym połączeniu, takim jak TCP, oraz zestawie pytań wysyłanych do serwera i odpowiedzi. Szczegóły dotyczące protokołu dostępne są w dokumencie [RFC01].