Nowoczesne technologie lingwistyczne

Joanna Satoła-Staśkowiak

Cele przedmiotu

- Omówienie wybranych nowoczesnych technologii lingwistycznych, wspierających proces uczenia się, nauczania języków, zaawansowanego przeszukiwania Internetu w celu odnajdywania specjalistycznych treści, prowadzenia analiz językoznawczych opartych na współczesnych narzędziach badawczych.
- Omówienie zalet i wad wykorzystywania Internetu i niektórych nowoczesnych technologii lingwistycznych, np. w procesie tłumaczenia tekstów, tworzenia tekstów.
- Wprowadzenie zagadnienia korpusów językowych – paralelnych (równoległych) i porównawczych (anotowanych i nieanotowanych).
- Omówienie zagadnienia słowników elektronicznych w odniesieniu do tradycyjnych słowników drukowanych.

Nowe narzędzia elektroniczne w dziedzinie lingwistyki

Joanna Satoła-Staśkowiak

Nowoczesne narzędzia lingwistyczne

- platformy edukacyjne
- słowniki elektroniczne
- leksykony elektroniczne
- korpusy językowe (np. równoczesne / paralelne)
- wyszukiwarki kolokacji i konkordacja, oraz wiele innych pomocy
- automatyczne tłumaczenia językowe wraz z pamięcią językową

Nowoczesne narzędzia lingwistyczne

- Nowoczesne narzędzia lingwistyczne wspierają pracę uczących się języków obcych, nauczycieli języków, badaczy tendencji językowych, współczesnych lingwistów oraz tłumaczy.
- Wynikające z szybkości pracy z takimi narzędziami zalety zdecydowanie przeważają nad wadami. Należy jednak podkreślić, że każda metoda ma określone wady, o których należy pamiętać, by niwelować ewentualne błędne zachowania prowadzące do błędnych językoznawczych rezultatów.

Termin „sztuczna inteligencja”

- Sztuczna inteligencja, SI (ang. artificial intelligence, AI) – inteligencja wykazywana przez urządzenia sztuczne (w przeciwieństwie do inteligencji naturalnej). Termin ten utworzył John McCarthy. W potocznym rozumieniu jest ona często używana w kontekście „prawdziwej sztucznej inteligencji”. W informatyce i kognitywistyce oznacza także tworzenie modeli i programów symulujących choć częściowo zachowania inteligentne. Sztuczna inteligencja jest także przedmiotem rozważań filozofii (filozofia sztucznej inteligencji) oraz przedmiotem zainteresowania nauk społecznych.

- Termin „sztuczna inteligencja” utworzył John McCarthy w 1956 na konferencji w Dartmouth. Andreas Kaplan i Michael Haenlein definiują sztuczną inteligencję jako „zdolność systemu do prawidłowego interpretowania danych pochodzących z zewnętrznych źródeł, nauki na ich podstawie oraz wykorzystywania tej wiedzy, aby wykonywać określone zadania i osiągać cele poprzez elastyczne dostosowanie”. Sztuczną inteligencją zajmowali się m.in. Marvin Minsky, John McCarthy, Alan Turing, Edward Feigenbaum, Raj Reddy, Judea Pearl, Allen Newell, Herbert A. Simon.

Znaczenia

Sztuczna inteligencja ma dwa podstawowe znaczenia:

- jest to hipotetyczna inteligencja realizowana w procesie technicznym, a nie naturalnym;
- jest to nazwa technologii i dziedzina badań naukowych informatyki i kognitywistyki czerpiąca także z osiągnięć psychologii, neurologii, matematyki i filozofii.

Główne zadania badań nad sztuczną inteligencją

- Głównym zadaniem badań nad sztuczną inteligencją w drugim znaczeniu jest konstruowanie maszyn i programów komputerowych zdolnych do realizacji wybranych funkcji umysłu i ludzkich zmysłów, niepoddających się numerycznej algorytmizacji. Problemy takie bywają nazywane AI-trudnymi i zalicza się do nich między innymi:
- podejmowanie decyzji w warunkach braku wszystkich danych,
- analiza i synteza języków naturalnych,
- rozumowanie logiczne/racjonalne,
- automatyczne dowodzenie twierdzeń,
- komputerowe gry logiczne, np. szachy,
- inteligentne roboty,
- systemy eksperckie i diagnostyczne.

Obszary sztucznej inteligencji

- Sztuczna inteligencja jest powiązana z obszarami uczenia maszynowego, logiki rozmytej, widzenia komputerowego, obliczeń ewolucyjnych, sieci neuronowych, robotyki i sztucznego życia.

Współczesne praktyczne zastosowania sztucznej inteligencji w humanistyce

Systemy eksperckie
systemy wykorzystujące bazę wiedzy (zapisaną w sposób deklaratywny) i mechanizmy wnioskowania do rozwiązywania problemów, także lingwistycznych
Lingwistyka komputerowa mająca związek z przetwarzaniem języków Naturalnych – praca z językowymi zasobami cyfrowymi.
Klasyfikacja języków
Maszynowe tłumaczenie tekstów
systemy tłumaczące nie dorównują człowiekowi, robią intensywne postępy, nadają się szczególnie do tłumaczenia tekstów technicznych.
Uczenie się maszyn
dział sztucznej inteligencji zajmujący się algorytmami potrafiącymi uczyć się, podejmować decyzje bądź nabywać wiedzę.
Eksploracja danych
omawia obszary powiązanie z potrzebami informacyjnymi, pozyskiwaniem wiedzy, stosowane techniki analizy i oczekiwane rezultaty.

Współczesne praktyczne zastosowania sztucznej inteligencji w humanistyce

Rozpoznawanie pisma (OCR) – stosowane już masowo,
np. do automatycznego sortowania listów, rozpoznawania treści życiorysów
oraz w elektronicznych notatnikach.

Sztuczna twórczość – istnieją programy automatycznie generujące **krótkie formy poetyckie**, komponujące, aranżujące i interpretujące utwory muzyczne, które są w stanie skutecznie „zmylić" nawet profesjonalnych artystów, tak, że ci nie uznają utworów za sztucznie wygenerowane.

Sieci neuronowe – stosowane z powodzeniem w wielu zastosowaniach łącznie z programowaniem „inteligentnych przeciwników" w grach komputerowych

Zastosowanie w innych dziedzinach wiedzy, przykłady

W ekonomii powszechnie stosuje się systemy automatycznie oceniające m.in. zdolność kredytową, profil najlepszych klientów czy planujące kampanie reklamowe. Systemy te poddawane są wcześniej automatycznemu uczeniu na podstawie posiadanych danych (np. klientów banku, którzy regularnie spłacali kredyt i klientów, którzy mieli z tym problemy).
W zarządzaniu inteligentne interfejsy – stosowane do zautomatyzowanego zarządzania, monitorowania, raportowania oraz podjęcia prób rozwiązywania potencjalnych problemów w procesach technologicznych.
W finansach prognozowanie i wykrywanie oszustw – przy użyciu m.in. regresji logistycznej systemy analizują zbiory danych w celu wychwytywania np. podejrzanych transakcji finansowych[8].
W transporcie analiza wideo w czasie rzeczywistym – znajduje zastosowanie m.in. w systemach monitoringu, systemach zarządzania ruchem samochodowym/pieszym i prognozowaniu takiego ruchu[

Nowoczesne narzędzia lingwistyczne - wady

Wady związane z korzystaniem z dostępnych w sieci narzędzi:

- absolutna wiara części użytkowników w fachowość narzędzia;
- zastępowanie własnych doświadczeń lingwistycznych obecnymi w sieci narzędziami i ich przykładami;
- niezwracanie uwagi na liczebną reprezentację przykładów prezentowanych w sieci;
- ograniczanie pracy nauczyciela do szukania gotowych rozwiązań, a tym samym do rezygnacji z własnych pomysłów;
- ograniczanie pracy tłumacza lub redaktora tekstów do szukania i stosowania najpopularniejszych terminów odnalezionych przez elektroniczne narzędzia korpusowe, do konwencjonalizacji tworzonych tekstów a także do zaniechania odważnych decyzji opartych na kreatywnych wyborach.

Nowoczesne narzędzia lingwistyczne - wady

- M. Wilkinson zauważa, że „niebezpieczeństwo nadmiernego przekształcania jest prawdopodobnie większe, jeżeli chodzi o narzędzia pamięci tłumaczeniowej, które zachęcają tłumaczy do uciekania się do dawnych rozwiązań i w ten sposób mogą zniechęcić ich do szukania nowych, kreatywnych sposobów (...)”

Nowoczesne narzędzia lingwistyczne - zalety

- **Zalety związane z korzystaniem z dostępnych w sieci narzędzi:**

zdecydowanie przeważają nad wadami (krótki czas dostępu do wiedzy, ciekawy sposób prezentacji problemu, ogromna liczba przykładów i omówień, a w przypadku korpusów językowych dostęp do dużej reprezentacji tekstów, wraz z informacjami o kolokacji czy konkordacji analizowanych jednostek, możliwość tworzenia tekstów, słowników, tłumaczeń);

Nowoczesne narzędzia lingwistyczne - zalety

- dzięki słownikom elektronicznym, wyszukiwarkom i korpusom językowym (języka pisanego i mówionego) znamy współczesne tendencje językowe, takie jak asymilacja anglicyzmów, skrótowość wypowiedzi, napór potocyzmów, emocjonalizmów w tym wulgaryzmów, itd. Zauważalne tendencje języka potwierdzają w przypadku korpusów językowych liczby użycia poszczególnych jednostek, fraz, zdań, itd.

Korpusy językowe

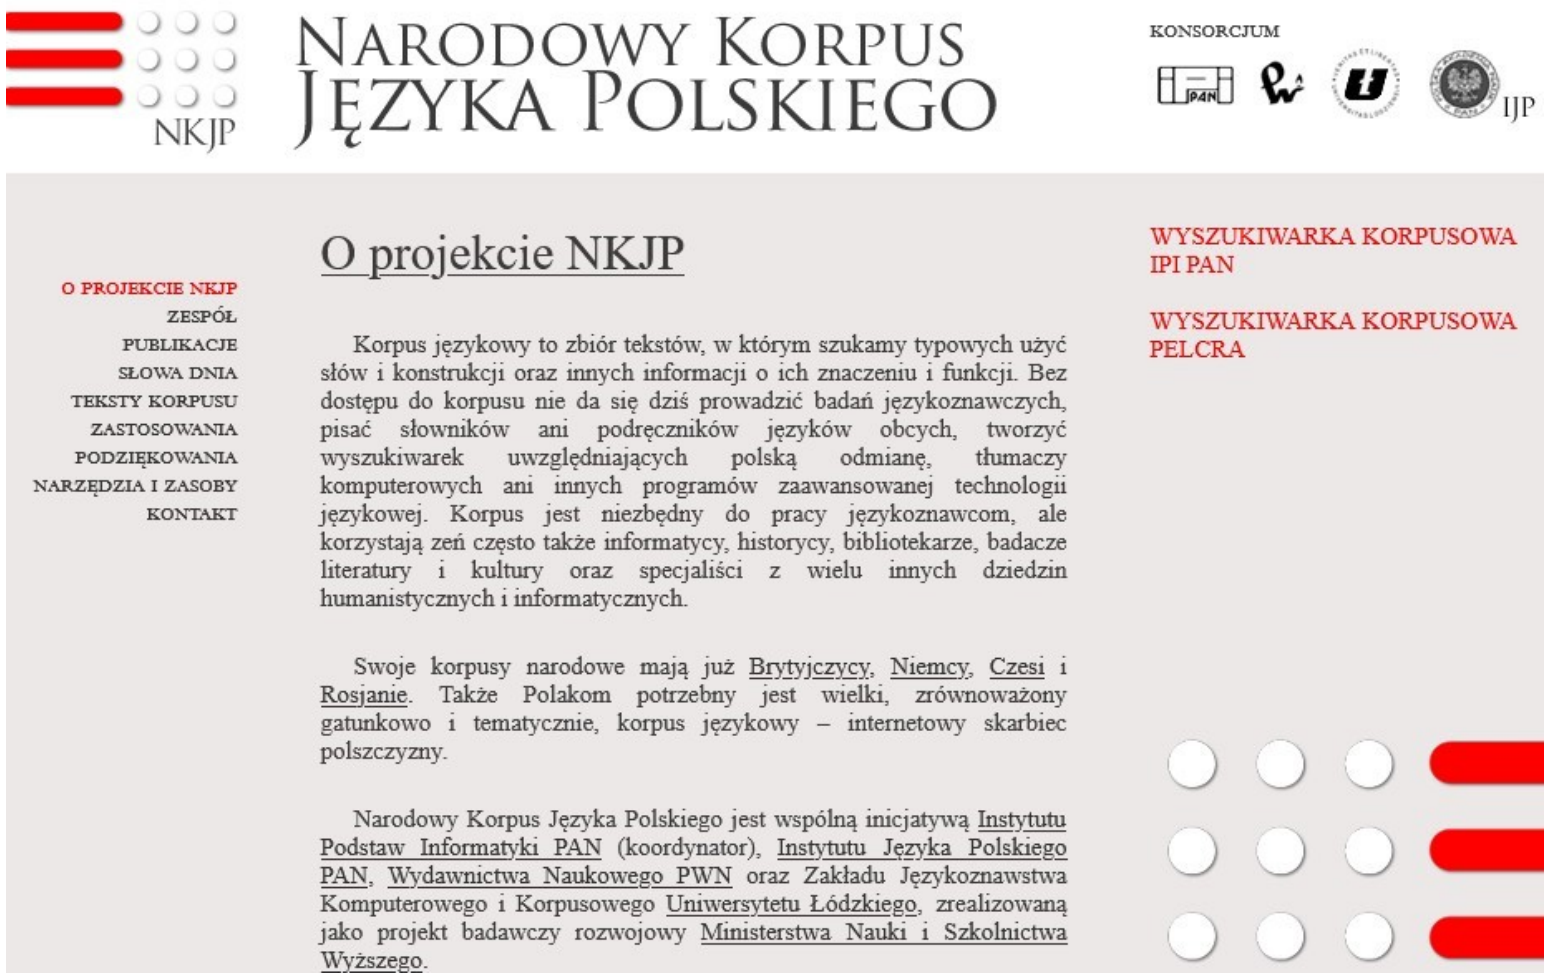
- **Korpus językowy**: „zbiór tekstów zapisanych w postaci cyfrowej i stanowiących reprezentatywną próbkę danego języka. Korpus różni się od dowolnego zbioru tekstów tym, że stanowi pewną przemyślaną całość. Cechą wyróżniającą korpusów komputerowych jest też ich rozmiar" [Piotrowski 2003: 146].
- korpusy językowe, z powodu dynamicznego rozwoju językoznawstwa korpusowego oraz technologii komputerowych, stały się ważnym materiałem badawczym, wykorzystywanym zarówno w językoznawstwie stosowanym [zob. Hunston 2002], jak i w leksykografii [zob. Ooi 1998].
- to zbiory tekstów służący badaniom lingwistycznym, np. określaniu częstości występowania form wyrazowych, konstrukcji składniowych, kontekstów w jakich pojawiają się dane wyrazy.
- korpusy językowe znalazły szerokie zastosowanie we współczesnej leksykografii. Są też wykorzystywane jako zbiory danych uczących i testowych w metodach uczenia maszynowego stosowanych w przetwarzaniu języków naturalnych.

Korpusy językowe - rodzaje

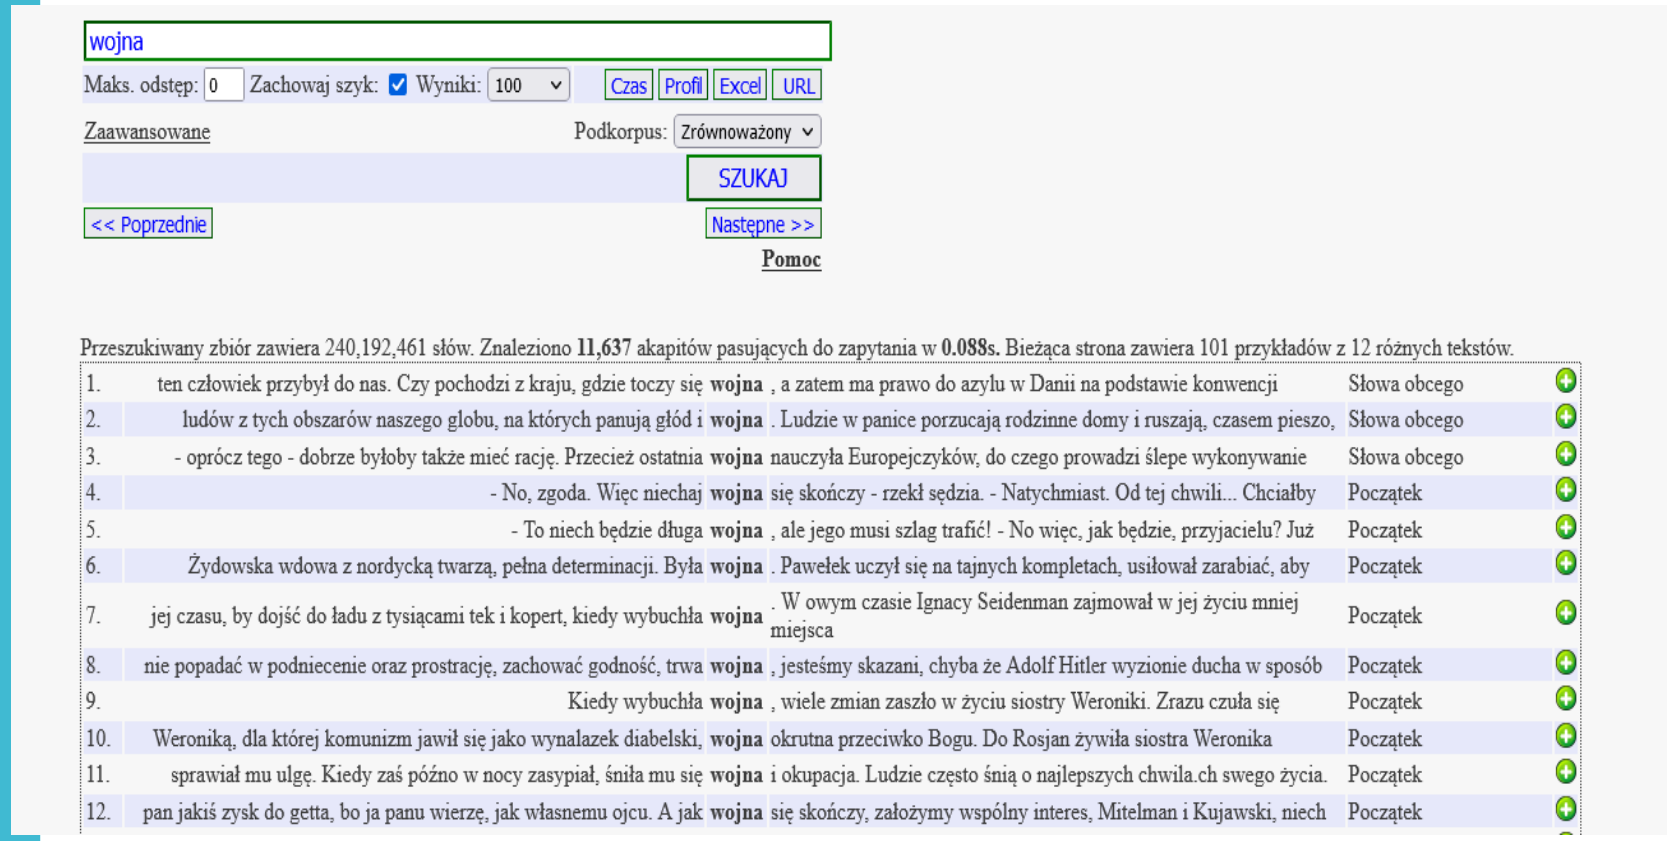
Ze względu na dostęp:

- **komercyjne** (do których dostęp mają osoby, które wykupią akces);
- **publiczne** (do których mają dostęp wszyscy użytkownicy Internetu)
- **indywidualne** (tworzone do własnych celów korpusy językowe (indywidulani badacze / grupy naukowców)

Narodowy Korpus Języka Polskiego



Narodowy Korpus Języka Polskiego



Wielki słownik języka polskiego



Korpusy językowe - rodzaje

- **Ze względu na prezentowany materiał językowy:**

zrównoważony – przygotowany według specjalnego klucza, tak by zapewnić pożądane proporcje pomiędzy różnymi stylami czy okresami powstawania tekstów. Przykładem korpusu zrównoważonego może być korpus Słownika frekwencyjnego polszczyzny współczesnej (obecnie znany także jako korpus polszczyzny lat sześćdziesiątych XX wieku), składający się w równych częściach (po 10000 próbek) z tekstów popularnonaukowych, drobnych wiadomości prasowych, publicystyki, prozy artystycznej i dramatu artystycznego.

równoległy - w którym każdy tekst ma swój odpowiednik w co najmniej jednym, innym języku. Teksty w takim korpusie mogą być zestawione (ang. aligned), np. na poziomie akapitu lub zdania.

https://paralela.clarin-pl.eu/#search/pl/domowy/-1/-1/0/20/0/true/0/0/-1/-1/-1/-1/source



Displaying segments 0 - 20 of 501 in 0.892 s. Index contains 18,886,623 segments.

TMX Range

Show / hide columns Show 20 entries

First Previous 1 2 3 4 5 Next Last

Lp	Polish	English
1	W ciągu ostatnich kilku tygodni urzędnicy zaostrzyli nadzór nad przeciwnikami rządu , a wobec wielu dysydentów , działaczy na rzecz praw człowieka i prawników zastosowano areszt domowy bądź prewencyjny . *Parlament Europejski*	Over the past few weeks , officials have stepped up their surveillance of critics of the government and many dissidents , activists and human rights lawyers have been either put under house arrest or taken into police custody . *European Parliament*
2	Aresztowania członków opozycji , zakłócenia pracy Sądu Najwyższego , odmowa wjazdu jednego z przywódców opozycji do kraju i areszt domowy drugiego , uwięzienie przedstawiciela ONZ i przemoc używana przez władze przeciwko pokojowym demonstrantom - wszystko to wskazuje na to , że Pakistan jest na skraju przepaści . *Parlament Europejski*	The arrests of members of the opposition , the disruption of the work of the Supreme Court , the refusal to allow one opposition leader into the country and the house arrest of another , the detention of a UN representative , and the violence used by the authorities against peaceful demonstrators all show that Pakistan is on the brink of a precipice . *European Parliament*

Kolokacja

- Korpusy językowe często informują użytkownika o **kolokacji** określonych słów, np. przymiotników występujących z rzeczownikami, rzeczowników z innymi rzeczownikami, albo przysłówków z czasownikami, itp. Informacje te są niesłychanie przydatne dla np. specjalistycznych tłumaczeń.
- Kolokacja daje informację np. o przymiotnikach niewystępujących w połączeniu z określonymi rzeczownikami, lub odwrotnie – pokazuje bogactwo form możliwych do zastosowania w tłumaczeniu przymiotników.
- Szukając kolokacji narzędzia korpusowe często wyświetlają nieoczekiwane wyniki. Należy w takim przypadku zwrócić uwagę na częstotliwość użyć analizowanych słów.
- Ogół specjalistycznych narzędzi wspomagających pracę tłumacza obejmuje termin CAT.

Własne korpusy językowe

- W opracowywanym własnym korpusie językowym wykorzystać możemy wszystkie dostępne w sieci narzędzia, np. narzędzia typu CAT pozwalające na:

1. zapisywanie tekstu oryginalnego i tekstu tłumaczonego jako jednostki tłumaczeniowe, co pozwoli na wykorzystywanie w kolejnych pracach tłumaczeniowych opartych na tej samej bądź zbliżonej tematyce.
2. segmentowanie (dzielenie na zdania i inne jednostki wspomagając tym samym tłumaczenie.
3. tworzenie własnych specjalistycznych baz
4. korzystanie z plików pamięci tłumaczeniowych, dbających o spójność tłumaczenia.