2.3 Typologia korpusów

Ponieważ w każdej dziedzinie badań naukowych istnieje niezmiennie potrzeba skategoryzowania elementów, które dziedzina ta obejmuje, także i w językoznawstwie korpusowym wyróżnia się szereg typów korpusów, różniących się przydatnością w konkretnych rodzajach badań. Klasyfikację (Lewandowska-Tomaszczyk 2005: 29) wprowadza się ze względu na *sposób gromadzenia materiału*, *zawartość danych korpusowych*, *reprezentatywność*, *format*, *organizację danych* oraz *cel badawczy*.

2.3.1 Korpusy referencyjne i monitorujące

Korpusy referencyjne (inaczej: *ogólne*, *statyczne*) to zbiory tekstów będące niejako „fotografią" stanu języka lub jego fragmentu w danym punkcie jego rozwoju[6]. Ponieważ są korpusami, będącymi podstawą odniesienia, powinny charakteryzować się możliwie największą reprezentatywnością, a co za tym idzie – dążeniem do obiektywności. W szczególności wymaga to ścisłego i dokładnie zaplanowanego zrównoważenia proporcji między tekstami pisanymi (które, co oczywiste, łatwiej jest gromadzić, ponieważ obecnie – dzięki rozwojowi Internetu i oprogramowania do odczytu dokumentów skanowanych – są bardziej dostępne) a mówionymi, a w ich obrębie – równowagi między poszczególnymi gatunkami oraz między tekstami o charakterze oficjalnym a prywatnymi (stąd – korpus zrównoważony). Po zgromadzeniu odpowiedniej ilości materiału obejmującego możliwie krótki okres korpus zamyka się i udostępnia do badań. Pierwsze korpusy elektroniczne miały taki właśnie charakter (patrz punkt 2.4.2).

[6] Ponieważ korpusy takie zawierają różne rodzaje tekstów, w tym zazwyczaj mówione i pisane, Aston i Burnard (1998) określają je mianem korpusów mieszanych, pojawia się także pojęcie korpusu uniwersalnego (Meyer 2002).

Korpusy monitorujące (inaczej: *dynamiczne*, *otwarte*, por. Kennedy 1998), w których dane zbiera się w sposób ciągły, stanowią więc już nie opis języka w danym punkcie czasu, jak korpusy referencyjne, a serię ujęć stanu języka. Korpusy takie pozwalają analizować tendencje zmian w języku w ciągu okresu, z którego teksty pochodzą, a więc wykorzystuje się w tym wypadku podejście diachroniczne do języka. Przy odpowiednio dużej ilości danych umożliwia to zbadanie stanu języka w dowolnie wybranym punkcie w czasie. Jedyne ograniczenie rozmiaru stanowią tu zasoby finansowe i technologiczne (Sinclair 1991). Ponadto, ponieważ gromadzenie danych do takich korpusów jest zazwyczaj mniej usystematyzowane (to znaczy w większym stopniu gromadzi się teksty w danej chwili dostępne i powstające), korpusy monitorujące są mniej reprezentatywne i mają charakter bardziej oportunistyczny. Ze względu na konieczność zaangażowania zasobów technologicznych potrzebnych do zgromadzenia danych, ich zapisania i przetworzenia, objęte są programami typowo komercyjnymi, a więc ich dostępność do badań naukowych jest ograniczona lub obciążona znacznymi kosztami (por. Kennedy 1998: 61). Ich przydatność do celów badawczych polega na ogromnej ilości zebranych danych i możliwości obserwowania nieustannie zmieniającego się języka.

2.3.2 Korpusy ogólne i specjalistyczne

Korpusy ogólne mają odzwierciedlać język niezawierający wypowiedzi o charakterze specjalistycznym bądź dialektowym, a więc stanowią zbiór tekstów o charakterze codziennym, popularnym. Służą do formułowania generalnych wniosków, na przykład o stosowanym przez użytkowników słownictwie i gramatyce.

Korpusy specjalistyczne[7] to takie, w których gromadzi się teksty stanowiące pewien wycinek systemu języka ograniczony do pewnej grupy jego użytkowników i konkretnych sytuacji (np. język dokumentów patentowych, język umów cywilno-prawnych, język rzemiosła, język blogów internetowych[8], subkultur młodzieżowych, osób uczących się danego języka[9] itd.). Przykładem takiego korpusu jest zbiór nagrań i ich transkrypcji, obrazujący rozwój kompetencji językowych u dzieci (Carterette, Jones 1974), *Michigan Corpus of Academic Spoken English* (MICASE) (Poos, Simpson 2002) oraz korpus języka angielskiego używanego w przemyśle naftowym (Zhu 1989).

Tego typu zbiorem jest ponadto korpus wykorzystywany w badaniach przedstawionych w niniejszej pracy, czyli kompletny zbiór tekstów opublikowanych w czasopiśmie naukowym zajmującym się naukami przyrodniczymi i medycznymi z określonego okresu.

2.3.3 Korpusy pełnotekstowe i próbkowane

Korpusy pełnotekstowe są rodzajem korpusów, w których gromadzi się teksty w całości, co jest podejściem typowym i najprostszym w konstruowaniu korpusów.

Korpusy próbkowane – zawierają fragmenty tekstów o określonej długości. Takie podejście może być podyktowane dążeniem do osiągnięcia maksymalnej reprezentatywności, aby odzwierciedlić system języka możliwie najpełniej, bądź ograniczeniem docelowej wielkości korpusu ze względów technologicznych. Należy pamiętać, że w badaniach stylistyki lub dyskursu ograniczony rozmiar próbek może nie wystarczyć do sformułowania jednoznacznych tez. Summers (1991: 5) stwierdza, że „główną zasadą przy

[7] Meyer (2002) wprowadza pojęcie korpusu do celów specjalnych (w odróżnieniu od korpusu uniwersalnego).
[8] Jung 2007.
[9] Xunfeng, Kawecki 2001.

ustalaniu sposobu próbkowania tekstów jest szeroka gama rodzajów tekstów zdefiniowana w sposób obiektywny". Pierwszy korpus elektroniczny Kučery i Francisa (1967) miał taki właśnie charakter.

2.3.4 Korpusy języka pisanego i mówionego

Nie ulega wątpliwości, że korpus, który ma charakteryzować się możliwie największą reprezentatywnością, musi zawierać teksty pisane i mówione. Problemem jest jednak ustalenie ich proporcji. Wydaje się oczywiste, że język mówiony jest wykorzystywany przez typowego użytkownika częściej niż pisany. Z drugiej jednak strony tekst pisany może być rozpowszechniany w ogromnym nakładzie, zaś pojedyncza rozmowa – rozgrywać się wyłącznie między dwojgiem ludzi, co oznacza, że tekst w pierwszym przypadku oddziałuje na wiele osób, w przeciwieństwie do sytuacji drugiej.

Korpusy języka pisanego – dzięki dostępności wielu rodzajów tekstów w sieci WWW (teksty publicystyczne, naukowe, literackie, blogi internetowe itd.), a także coraz większym możliwościom oprogramowania odczytującego teksty pisane (OCR[10]) zbiory tekstów pisanych gromadzi się łatwo (niekiedy łatwość gromadzenia niektórych typów tekstów może negatywnie rzutować na reprezentatywność, łatwiej bowiem na przykład zgromadzić teksty z gazet bądź czasopism niż korespondencję prywatną), choć rzecz jasna nie odzwierciedlają one systemu języka. Ponadto korpusy te były chronologicznie pierwsze – korpusy języka mówionego pojawiły się w językoznawstwie później.

Korpusy języka mówionego – stanowią niezbędny element korpusów referencyjnych. Niektóre takie korpusy (na przykład *Survey of English Dialects*) istniały przez pewien czas jedynie w postaci nagrań, co stanowi odstępstwo od wymogu zapisania korpusu. Gromadzenie korpusów języka

[10] Por. Hussmann, Deng 2005, Taghva, Stofsky 2001, Nakano 2000.

mówionego, a więc – nagrywanie użytkowników w sytuacjach najbardziej zbliżonych do naturalnych (oznacza to na przykład, że nagrywanie odczytów lub sztuk teatralnych nie jest rozwiązaniem optymalnym, ponieważ – mimo że mówione – teksty odzwierciedlają słowo pisane), a następnie transkrypcja i ewentualna adnotacja nagrań, jest procesem niezwykle kosztownym i długotrwałym. Obecnie – wraz z rozwojem technologii komputerowej – dostępne są także specjalistyczne korpusy języka mówionego (patrz Lamel et al. 1991, Svartvik, Quirk 1980, Knowles et al. 1992, Otwinowska-Kasztelanic 2000 w sprawie korpusu języka mówionego młodego pokolenia Polaków, Meyer 2002 w sprawie ograniczeń korpusów języka mówionego, Clopper et al. 2006).

2.3.5 Korpusy jednojęzyczne i wielojęzyczne, równoległe i porównywalne

Korpusy jednojęzyczne – gromadzą teksty w jednym języku (na przykład korpusy narodowe: amerykański, brytyjski, czeski, grecki, rosyjski (Sharoff 2003), słowacki, a także *Brown Corpus*, *The Helsinki Corpus of English Texts*).

Korpusy wielojęzyczne (na przykład korpus *Hansard*, korpus *EuroParl*[11], korpus *JRC-Acquis*[12]) – zawierają teksty w więcej niż jednym języku, przy czym musi istnieć między tekstami pewien związek (o typach związku por. niżej), a więc wyklucza się przypadkowość.

Korpusy wielojęzyczne równoległe (inaczej: paralelne) – zawierają teksty oryginalne i ich przekłady na język lub języki obce. Korpusy takie mogą być uporządkowane względem zdań – to znaczy określa się, które zdania w tekście oryginalnym są ekwiwalentami zdań w tłumaczeniu – lub pojedynczych wyrazów. Im większa jednak dokładność takiego

[11] http://www.statmt.org/europarl
[12] http://langtech.jrc.it/JRC-Acquis.html

uporządkowania, tym większa liczba przypadków, w których ekwiwalencja (zdania lub wyrazu) nie jest typu „podmiany 1:1" (Lewandowska-Tomaszczyk 2005: 85). Jednym z przykładów jest tu korpus CRATER (McEnery et al. 1997). Innym przykładem takiego korpusu obejmującego szereg języków europejskich jest baza aktów prawnych Wspólnot Europejskich Eurlex (http://eur-lex.europa.eu/pl/index.htm), zawierająca ogromną liczbę dyrektyw, rozporządzeń i projektów tłumaczonych na języki wszystkich, obecnie 27, Państw Członkowskich. Korpusy takie należy traktować z pewną ostrożnością, ponieważ zazwyczaj tłumaczenie wymusza zmniejszenie naturalności tekstu wynikowego. Ponadto teksty takie narażone są na wszelkie typowe błędy tłumaczeniowe wywołane na przykład interferencją. Przykładem jest tu przenoszenie swobodnego szyku wyrazów z języka polskiego do języka angielskiego, w którym szyk wyrazów ma charakter bardziej stały; z kolei przy tłumaczeniu w odwrotnym kierunku następuje stosowanie zapożyczeń w miejsce istniejących wyrazów rodzimych; na przykład *ogrzewanie pod refluksem* (ang. *under reflux*) zamiast *pod chłodnicą zwrotną* (por. Dzierżanowska 1990).

Korpusy wielojęzyczne porównywalne – zawierają teksty podobne, jednak nie identyczne treściowo, które łączyć może tematyka, data powstania, autor itd., konstruowane za pomocą tych samych reguł (ang. *sampling frame*). Porównywalność tekstów w dwóch językach może wiązać się z następującymi kategoriami (Lewandowska-Tomaszczyk 2005: 52): tematyka (identyczna lub podobna dziedzina, ewentualnie podział na poddziedziny w ramach poszczególnych dziedzin), okres powstania (podobny dla tekstów w obu językach, znaczenie ma tu rzecz jasna szybkość rozwoju danej tematyki), styl (podobna charakterystyka stylistyczna), typ publikacji (teksty książkowe, prasowe itd.), środek przekazu (jeśli na przykład w jednym języku gromadzi się teksty mówione, w języku drugim powinny także występować teksty tego rodzaju). Zaletą tego typu korpusów jest naturalność tekstów, to znaczy brak interferencji związanej z tym, że tekst powstaje jako tłumaczenie z języka obcego. Interferencja może dotyczyć wszystkich aspektów tekstu (leksyka, składnia, stylistyka itd.). Przykładem korpusów zawierających teksty napisane

w jednym języku, ale porównywalnych ze sobą, są *Brown Corpus*[13] (odmiana amerykańska języka angielskiego) oraz wzorowane na nim (to znaczy opracowywane zgodnie z tymi samymi zasadami) *LOB Corpus*[14] (odmiana brytyjska) i *Kolhapur Corpus*[15] (odmiana indyjska). Z kolei typowymi korpusami porównywalnymi są *Aarhus Corpus of Contract Law* (języki duński, angielski, francuski) oraz projekt PAROLE[16] (języki państw członkowskich Unii Europejskiej).

2.3.6 Korpusy nieanotowane i anotowane

Korpusy nieanotowane (nieindeksowane) zawierają wyłącznie tekst, co oznacza, że teksty po zgromadzeniu nie zostały wzbogacone o żadne informacje dodatkowe. Korpus nietagowany ma ograniczone zastosowanie do uzyskiwania miarodajnych list frekwencyjnych, ponieważ te same wyrazy mogą pełnić różne funkcje gramatyczne (Biber et al. 1998: 30).

Korpusy anotowane zawierające dodatkowe informacje o tekstach:

a) dane o formatowaniu zastosowanym w dokumencie, czyli użyte czcionki (ważne w analizie dyskursu, na przykład znaczenie dyskursywne kursywy i wytłuszczenia), podział na strony i akapity,

b) dane o samym tekście – autor, jego płeć (istotna przede wszystkim w przypadku korpusów języka mówionego), pochodzenie i wykształcenie, rok powstania lub nagrania, gatunek,

[13] Francis, Kucera 1964.
[14] Johansson et al. 1986.
[15] Shastri 1985, Shastri 1988.
[16] Calzolari et al. 1996.

c) dane metajęzykowe, do których zalicza się etykiety części mowy, części zdania (typ fraz), cechy prozodyczne (informacje tego rodzaju podawał już *Survey of English Usage* z lat 60. XX wieku, Kaye 1988) lub transkrypcję w przypadku tekstów mówionych, dane semantyczne i leksykalne.

Dzięki anotowaniu łatwiejsze staje się wykorzystywanie informacji zgromadzonych w korpusie, nawet przez osoby nieznające danego języka, możliwe jest prowadzenie wielokrotnych analiz korpusu, a ponadto zwiększa się ich przejrzystość (McEnery 2003: 454–455).

Wymagania dla operacji anotowania podaje Leech (1993):

a) powinna istnieć możliwość łatwego oddzielenia adnotacji od treści korpusu, co również oznacza, że należałoby unikać wstawiania adnotacji wewnątrz wyrazów korpusu (drugi warunek ma znaczenie tylko dla odczytywania korpusu, ponieważ za pomocą narzędzi komputerowych właściwie oznaczone adnotacje łatwo jest oddzielić od treści),

b) powinna istnieć możliwość wyodrębnienia adnotacji z tekstu korpusu, co pozwala na ich oddzielną analizę,

c) wszystkie symbole zastosowane w adnotacjach należy dokładnie opisać, aby użytkownik korpusu miał pełną jasność co do ich znaczenia; pomocne jest ponadto dobranie symboli w sposób ułatwiający ich interpretację (na przykład oznaczenie przyimka symbolem PREP lub podobnym zamiast kodu liczbowego), a zatem w sposób możliwie intuicyjny,

d) należy podać zastosowaną metodę anotowania korpusu oraz podać informacje o ewentualnych poprawkach wprowadzanych ręcznie,

e) konwencje zastosowane przy adnotowaniu powinny być w możliwie największym stopniu zgodne z rozpowszechnionymi w praktyce badawczej zasadami, co do których istnieje możliwie największa zgoda.

Krytycy korpusów anotowanych twierdzą, że dodatkowe informacje narzucają jedną, określoną interpretację korpusu (można jednak rzecz jasna zawsze zaproponować interpretację własną, odmienną od oryginalnej). Ponadto niedokładności procesu anotowania, a więc konieczność anotowania manualnego, wprowadzają niespójność adnotacji (por. McEnery 2003: 456–457, Sinclair 1992).

2.3.7 Korpusy synchroniczne i diachroniczne

Korpusy synchroniczne – gromadzone w możliwie krótkim przedziale czasu, przez co mogą być uznawane za obraz stanu języka w danym punkcie jego rozwoju.

Korpusy diachroniczne, określane także jako korpusy historyczne – zawierają teksty powstałe na przestrzeni dłuższego czasu. Wykorzystywane są w badaniach leksykograficznych i analizie dyskursu, a także badaniach dialektologicznych i stylistycznych (Biber et al. 1998: 204). Przykładem jest tu *The Helsinki Corpus of English Texts* (patrz rozdział 2, punkt 4.2) oraz *Complete Corpus of Old English*.