Przetwarzanie Języka Naturalnego (NLP)

- Przetwarzanie języka naturalnego to interdyscyplinarna dziedzina AI, która umożliwia maszynom analizowanie, interpretowanie i generowanie języka ludzkiego. NLP integruje informatykę, lingwistykę, statystykę i uczenie maszynowe, tworząc narzędzia zdolne do rozumienia dużych zbiorów tekstów i mowy.

Dlaczego NLP jest kluczowe?

- NLP umożliwia automatyzację zadań językowych, analizę ogromnych korpusów, interpretację zapytań użytkowników, budowę inteligentnych asystentów oraz wspiera badania naukowe. Współczesna gospodarka opiera wiele procesów na przetwarzaniu języka.

Definicja i Zakres NLP

- NLP skupia się na szkoleniu maszyn do rozumienia i generowania języka. Obejmuje zadania takie jak analiza tekstu, modelowanie semantyczne, interpretacja kontekstu, rozpoznawanie mowy, dialog, tłumaczenie i streszczanie.

Główne Zadania NLP

- Do najważniejszych zadań NLP należą: rozpoznawanie mowy, klasyfikacja tekstu, analiza semantyczna, generowanie tekstu, NLU i NLG. Te procesy umożliwiają komunikację między człowiekiem a maszyną.

Komponenty NLP: Składnia

- Składnia bada strukturę zdań. Modele NLP analizują, czy zdania są poprawnie zbudowane i identyfikują relacje między słowami. Poprawne parsowanie składniowe jest fundamentem dla bardziej zaawansowanych analiz.

Komponenty NLP: Semantyka

- Semantyka pozwala modelom rozpoznawać znaczenia słów i fraz oraz określać relacje semantyczne. Techniki embeddingowe i transformatorowe pozwalają odzwierciedlać podobieństwo znaczeniowe w przestrzeniach wektorowych.

Komponenty NLP: Pragmatyka

- Pragmatyka uwzględnia kontekst wypowiedzi, intencje nadawcy i sytuację komunikacyjną. Modele NLP oparte na transformatorach potrafią uchwycić zależności pragmatyczne dzięki mechanizmowi atencji.

Komponenty NLP: Dyskurs

- Analiza dyskursu bada powiązania między zdaniami i kohezję tekstu. Jest kluczowa w streszczaniu, QA, koreferencji i budowie spójnych dialogów.

Fazy Przetwarzania Tekstu

- Przetwarzanie tekstu obejmuje analizę leksykalną, składniową, semantyczną, integrację dyskursu oraz analizę pragmatyczną. Każda faza przybliża model do pełnego rozumienia.

Tokenizacja i Normalizacja

- Tokenizacja dzieli tekst na jednostki, a normalizacja usuwa szum językowy, standaryzując dane. Procesy te przygotowują materiał do uczenia modeli na dużą skalę.

Stemming i Lemmatyzacja

- Stemming skraca słowa, natomiast lematyzacja przywraca ich formy słownikowe. To kluczowe dla redukcji wymiarowości i ujednolicenia języka.

Embeddings: Word2Vec, GloVe, BERT

- Embeddingi reprezentują słowa jako wektory. Modele takie jak Word2Vec i GloVe uchwycają statystyczne wzorce, natomiast modele kontekstowe (np. BERT) uwzględniają lokalny kontekst, generując bardziej precyzyjne wektory.

Transformery: Przełom w NLP

- Transformatory wykorzystują mechanizm atencji, który pozwala na równoległe przetwarzanie sekwencji i wychwytywanie długich zależności. Zastąpiły RNN, LSTM i GRU w większości zastosowań.

Mechanizm Atencji

- Atencja pozwala modelom ocenić ważność każdego tokena względem innych tokenów. Wielogłowicowa atencja umożliwia jednoczesne analizowanie różnych aspektów znaczeniowych.

LLMs: GPT-3, GPT-4, BERT

- Duże modele językowe posiadają setki miliardów parametrów i potrafią generować, tłumaczyć, streszczać i analizować tekst na poziomie zbliżonym do ludzkiego, wykorzystując uczenie transferowe.

Analiza Sentymentu

- Techniki analizy sentymentu identyfikują emocjonalny ton wypowiedzi. Stosuje się podejścia leksykalne, uczenie maszynowe i modele głębokie.

Tłumaczenie Maszynowe

- Tłumaczenie ewoluowało od modeli statystycznych do neuronowych. Najnowsze modele transformatorowe dominują w systemach takich jak DeepL i Google Translate.

NER: Rozpoznawanie Jednostek Nazwanych

- NER identyfikuje jednostki, takie jak osoby, miejsca i organizacje. Jest kluczowe w systemach ekstrakcji informacji i analizie dokumentów.

Analiza Syntaktyczna i Dependency Parsing

- Dependency parsing wykrywa relacje gramatyczne i hierarchię składniową. Modele transformatorowe wprowadziły nowy poziom dokładności w analizie gramatycznej.

Streszczanie Tekstu

- Streszczanie ekstraktywne wybiera kluczowe fragmenty. Abstraktywne generuje nowe zdania. Modele takie jak PEGASUS osiągają wysoki poziom spójności.

Systemy QA

- Systemy odpowiadania na pytania znajdują precyzyjne odpowiedzi poprzez analizę pytania, wyszukiwanie dokumentów i ekstrakcję informacji.

Koreferencja

- Koreferencja identyfikuje elementy odwołujące się do tej samej jednostki, co jest kluczowe dla spójności interpretacji i streszczania.

Semantic Role Labeling

- SRL przypisuje role semantyczne argumentom czasownika, tworząc strukturę predykat-argument, która pozwala rozumieć relacje zdarzeniowe.

Grafiki Wiedzy i Łączenie Jednostek

- Grafiki wiedzy strukturyzują relacje między jednostkami. NLP umożliwia ekstrakcję i przypisywanie encji do odpowiednich węzłów.

ASR: Rozpoznawanie Mowy

- ASR konwertuje mowę na tekst dzięki modelom akustycznym, językowym i podejściu end-to-end, które obecnie dominuje w systemach transkrypcji.

Wyzwania NLP

- Modele NLP napotykają trudności wynikające z dwuznaczności języka, idiomów, stronniczych danych oraz wysokich kosztów energetycznych treningu.

NLP w Tłumaczeniach

- W ocenie jakości tłumaczenia stosuje się modele pretrenowane, analizę ról semantycznych i mechanizmy atencji, aby ocenić zgodność znaczeniową tłumaczeń.

Podsumowanie

- NLP przeszło ewolucję od systemów regułowych do zaawansowanych modeli transformatorowych. Dzisiejsze LLMs stanowią fundament współczesnych narzędzi językowych.