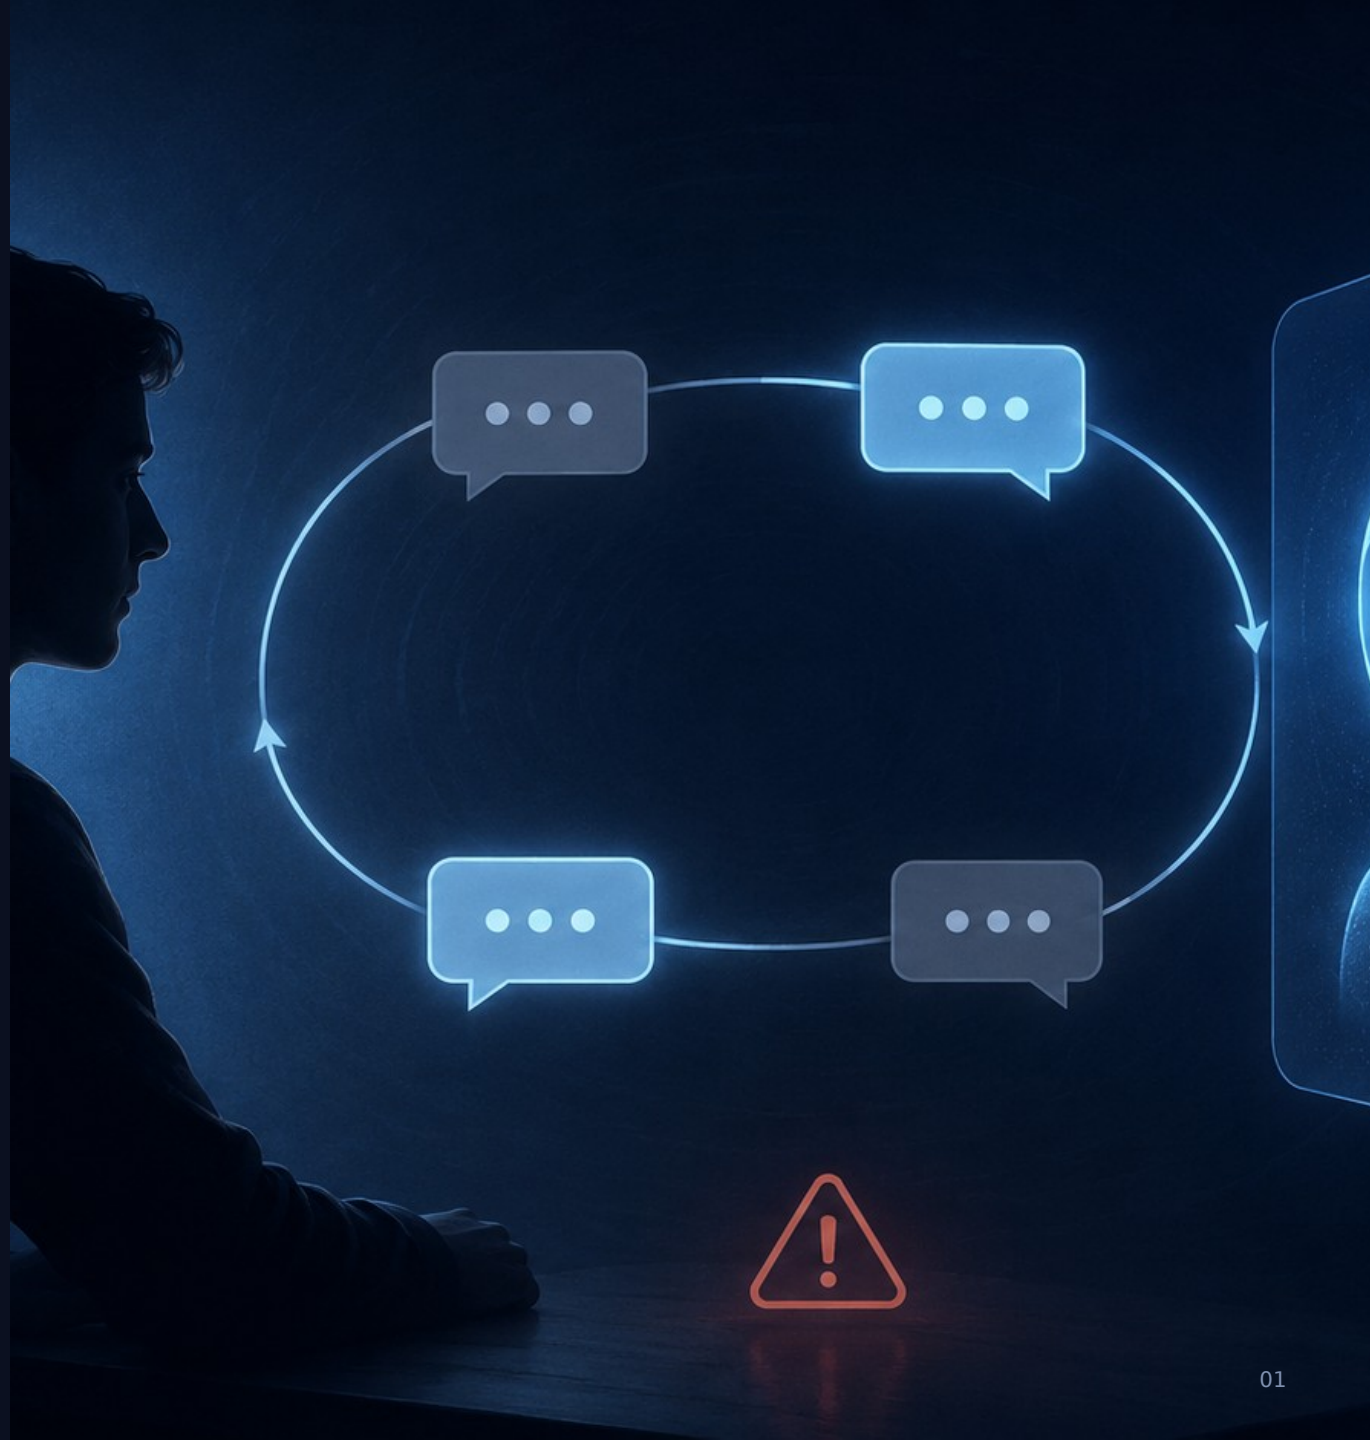
WYKŁAD / NLP / CYBERBEZPIECZEŃSTWO

Chatboty jako narzędzia działalności przestępczej

Od ELIZY do generatywnych „person”:
architektura, zastosowania i ryzyka społeczne



Główna teza dokumentu

Technologia konwersacyjna ma charakter podwójny: usprawnia komunikację i jednocześnie poszerza arsenał cyberprzestępczy.

Chatbot nie jest tylko „rozmówcą”. To interfejs, który może automatyzować, personalizować i skalować oddziaływanie na człowieka.

Potencjał legalny	Potencjał nadużycia
obsługa klienta, edukacja, administracja, asystenci głosowi, personalizacja usług	dezinformacja, socjotechnika, botnety, cyberstalking, automatyzacja oszustw

Problem dydaktyczny:

Jak uczyć o chatbotach bez technoentuzjazmu i bez moralnej paniki?

Klucz: architektura + historia + studium przypadku + ramy prawne + krytyczna analiza ryzyka.

Oś rozwoju: od robota do chatbota

Historia pokazuje przesunięcie od mechanicznej automatyzacji ku dialogowi, emocjom i personalizacji.

1920s

Čapek

„robot” jako praca / maszyna humanoidalna

1950

Turing

czy maszyny mogą myśleć?

1964–66

ELIZA

reguły i słowa kluczowe

1972

PARRY

symulacja pacjenta

1995

A.L.I.C.E.

AIML i wzorce

2010s

Siri / Alexa

głos + NLP + ekosystem usług

2020s

GenAI

persony, automatyzacja, ryzyko nadużyć

Wniosek: im bardziej naturalna interakcja, tym większe znaczenie odpowiedzialnego projektowania i kontroli użycia.

Kamienie milowe chatbotów

Od systemów regułowych do modeli uczących się kontekstu i głosu użytkownika.

ELIZA

rozpoznawanie słów kluczowych; odpowiedzi oparte na prostym przekształceniu wypowiedzi użytkownika

PARRY

bardziej wiarygodna symulacja roli; przykład wczesnej „persony” komputerowej

A.L.I.C.E.

silnik chatbota + model wiedzy językowej; tysiące reguł AIML

SmarterChild

masowe doświadczenie rozmowy z asystentem; całodobowa dostępność i silne zaangażowanie użytkowników

Siri

ASR, NLU, synteza mowy i integracja z ekosystemem urządzeń mobilnych

Alexa

interfejs głosowy + IoT; polski wątek technologii IVONA Software

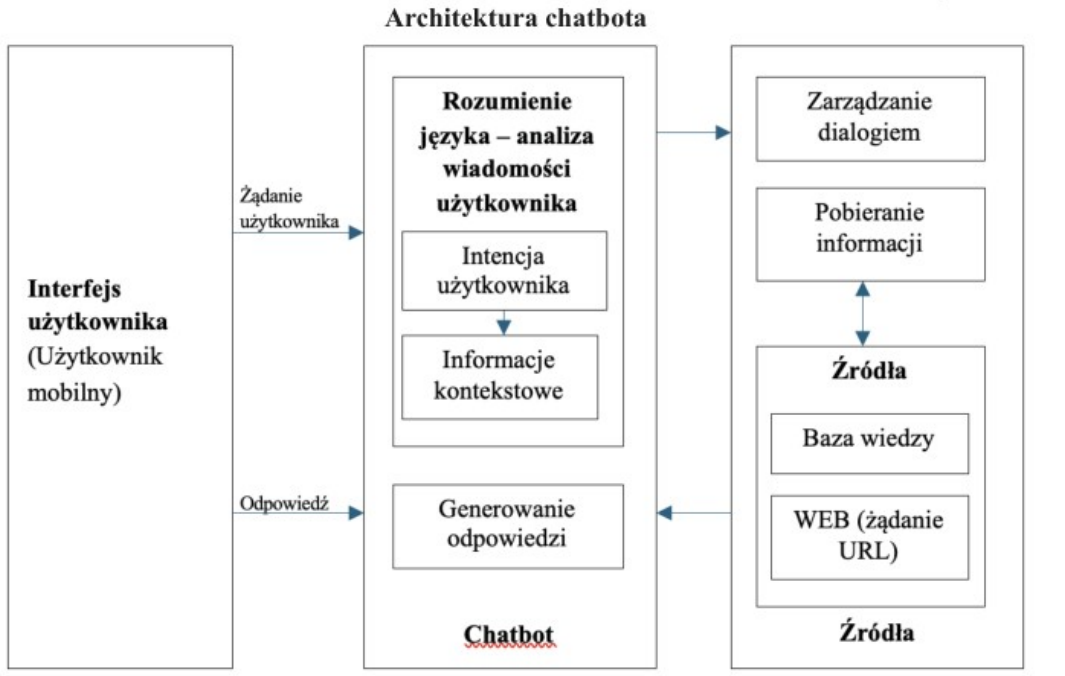
XiaoIce

chatbot społecznościowy: relacja, emocje, długotrwała interakcja

Architektura chatbota

Dokument rozpisuje chatbota jako system modułów: interfejs → rozumienie języka → zarządzanie dialogiem → źródła danych → generowanie odpowiedzi.

Rysunek 1



Źródło: X. Huang and ASCS CIS, *Chatbot: design, architecture, and applications*, Pennsylvania 2021

Źródło grafiki: X. Huang and ASCS CIS, za: Płachecka, rys. 1.

Co to oznacza dla zajęć?

Studenci powinni analizować nie tylko odpowiedź chatbota, ale cały przepływ: wejście użytkownika, klasyfikację intencji, kontekst, źródła danych i mechanizm generacji.

Kluczowa obserwacja: każde ogniwo może być punktem awarii, manipulacji lub nadużycia.

Jak działa rozmowa z chatbotem?

Model dydaktyczny: wejście → interpretacja → decyzja → odpowiedź → sprzężenie zwrotne.

1 Wejście

tekst, głos, obraz lub sygnał użytkownika

2 NLU

intencja, encje, kontekst, klasyfikacja aktu dialogowego

3 DM

decyzja: co system powinien zrobić dalej

4 Źródła

baza wiedzy, API, historia rozmów, dane zewnętrzne

5 Odpowiedź

tekst, głos, akcja, rekomendacja lub przekierowanie

Pytanie kontrolne dla studentów:

W którym miejscu tego procesu najłatwiej wprowadzić manipulację, błąd lub naruszenie prywatności?

Dualny charakter chatbotów

Ta sama technologia może wzmacniać usługi albo eskalować przemoc cyfrową.



Katalizator innowacji

- automatyzacja obsługi i administracji
- asystenci głosowi i dostępność usług
- edukacja, personalizacja i wsparcie użytkownika

Katalizator ryzyka

- dezinformacja i treści perswazyjne
- socjotechnika i oszustwa finansowe
- cyberstalking i multiplikacja „person”

Niebezpieczeństwo nie leży wyłącznie w samym modelu, ale w sposobie jego integracji z danymi, platformami i realnym życiem ofiar.

Studium przypadku: James Florence

Przypadek pokazuje przejście od cyberstalkingu do zautomatyzowanej, spersonalizowanej przemocy cyfrowej.

2008–2014	**wczesny cyberstalking**	nękanie, podszywanie się, fałszywe zgłoszenia
2015–2019	**eskalacja**	doxxing, materiały seksualizujące, przejmowanie kont
2020–2023	**systemy generatywne**	chatboty-persony ofiary, ujawnianie danych, przejście online–offline
2024–2025	**reakcja prawna**	dowody cyfrowe, przyznanie się do winy, wyrok i nadzór

Najważniejsza zmiana: chatbot przestaje być tylko kanałem komunikacji — staje się generatorem „symulowanej osoby” i narzędziem mostowania online–offline.

Mechanizm nadużycia

Co konkretnie zmienia generatywny chatbot w przestępstwie cyfrowym?

1

automatyzuje kontakt i multiplikuje skalę

2

personalizuje przekaz na bazie danych ofiary

3

tworzy wiarygodną personę / awatar relacyjny

4

przenosi skutki do świata fizycznego

5

utrudnia usuwanie śladów na wielu platformach

Tradycyjne kategorie cyberprzestępczości są niewystarczające, gdy system generatywny działa jako interaktywny, powielalny i wiarygodny zastępnik osoby.

Ramy cyberbezpieczeństwa

Dokument wskazuje potrzebę powiązania badań nad chatbotami z systemem instytucjonalnym.

Prawo	Edukacja	Technologia	Współpraca
doprecyzowanie definicji botów i botnetów; odpowiedzialność operatorów platform; zgodność z ochroną danych	cyberhigiena, rozpoznawanie symptomów ataku, przygotowanie instytucji i obywateli do reakcji	detekcja anomalii, wczesne ostrzeganie, neutralizacja botnetów blisko czasu rzeczywistego	koordynacja międzynarodowa, wymiana danych, procedury dowodowe, ochrona ofiar

Instytucje wskazane w tekście: CSIRT GOV, CSIRT NASK, CSIRT MON, NASK — jako elementy krajowego systemu cyberbezpieczeństwa.

Wniosek: problem chatbotów nie jest wyłącznie techniczny. Wymaga prawa, edukacji, infrastruktury obronnej i badań interdyscyplinarnych.

Propozycja ćwiczenia dla studentów

Analiza ryzyka chatbota jako systemu społeczno-technicznego.

Zadanie: wybierzcie dowolnego chatbota / asystenta i opiszcie jego potencjał użyteczny oraz potencjał nadużyć.

1. Funkcja	2. Dane	3. Interakcja	4. Ryzyko	5. Ochrona
Do czego system został zaprojektowany?	Jakie dane wejściowe i kontekstowe przetwarza?	Czy może wpływać na emocje, decyzje lub zachowanie użytkownika?	Jak można go nadużyć? Jakie są skutki online/offline?	Jakie bariery techniczne, prawne i edukacyjne są potrzebne?

Produkt końcowy: 1 slajd z mapą ryzyka + 3 rekomendacje ograniczające nadużycia.

Pytania do dyskusji

Wykład można zakończyć debatą nad granicami odpowiedzialności człowieka i maszyny.

1. **Czy chatbot powinien odpowiadać za skutki generowanych interakcji, czy wyłącznie jego operator?**

2. **Czy platformy powinny wykrywać tworzenie „person” opartych na realnych osobach?**

3. **Jak odróżnić legalną personalizację od cyfrowej przemocy symbolicznej?**

4. **Czy edukacja użytkowników wystarczy bez twardych mechanizmów regulacyjnych?**

Podsumowanie

Najważniejsze wnioski z dokumentu w ujęciu dydaktycznym.

- chatboty przeszły drogę od prostych reguł do systemów generatywnych zdolnych do personalizowanej interakcji
- ich architektura łączy NLU, zarządzanie dialogiem, źródła danych i generowanie odpowiedzi
- przypadek Jamesa Florence’a pokazuje nową kategorię ryzyka: multiplikację person i mostowanie online–offline
- odpowiedź musi być interdyscyplinarna: prawo, edukacja, technologia, współpraca międzynarodowa
- w dydaktyce NLP warto łączyć analizę techniczną z analizą społeczną i prawną

Zamiast pytać tylko: „jak działa chatbot?”, należy pytać także: „co umożliwia, komu służy i jak może zostać użyty przeciwko człowiekowi?”.

Źródło i kontekst zajęć

Materiał do wykorzystania jako wykład w bloku NLP / AI / cyberbezpieczeństwo.

Podstawa prezentacji

Magdalena Płachecka, „Chatboty jako współczesna forma narzędzi działalności przestępczej”, Nr 3(159), s. 89–109.

Proponowane miejsce w kursie

- po wprowadzeniu do NLP, chatbotów i modeli generatywnych
- przed zajęciami o prompt injection, bezpieczeństwie i etyce AI
- jako studium przypadku do pracy grupowej i debaty

Dodatkowy efekt dydaktyczny: studenci widzą, że NLP nie jest tylko techniką przetwarzania tekstu, lecz częścią realnego środowiska społecznego, prawnego i bezpieczeństwa.